



UNIVERSIDAD DE MÁLAGA



E.T.S. INGENIERÍA
INFORMÁTICA
UNIVERSIDAD DE MÁLAGA

Máster en Ingeniería Informática

Mención en Ingeniería y Ciencia de Datos

**Hacia un Aprendizaje Automático Cuántico adaptado
para NISQ: estudio de modelos híbridos asistidos
por selección de características**

**Towards NISQ-suited Quantum Machine Learning:
Study of feature selection-assisted hybrid models**

Realizado por

Pablo Ruiz Muñoz

Tutorizado por

Dr. Gabriel Jesús Luque Polo

Co-tutorizado por

Dr. Zakaria Abdelmoiz Dahi

Departamento

Departamento de Lenguajes y Ciencias de la Computación

Málaga, Junio, 2026



UNIVERSIDAD
DE MÁLAGA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA
MÁSTER EN INGENIERÍA INFORMÁTICA
Mención en Ingeniería y Ciencia de Datos

**Hacia un Aprendizaje Automático Cuántico adaptado
para NISQ: estudio de modelos híbridos asistidos
por selección de características**

**Towards NISQ-suited Quantum Machine Learning:
Study of feature selection-assisted hybrid models**

Realizado por

Pablo Ruiz Muñoz

Tutorizado por

Dr. Gabriel Jesús Luque Polo

Co-tutorizado por

Dr. Zakaria Abdelmoiz Dahi

Departamento

Departamento de Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA

Fecha defensa: Julio, 2026

MÁLAGA, JUNIO, 2026

Resumen

La computación cuántica es un área de trabajo en auge en los últimos años. Actualmente nos encontramos en la era NISQ, donde los ordenadores cuánticos disponen de un número reducido de cúbits y son susceptibles al ruido afectando a la precisión de las operaciones realizadas. Bajo este contexto, existe una necesidad de demostrar la viabilidad práctica del aprendizaje automático cuántico. Por ello y ante la dificultad de codificar conjuntos de datos de alta dimensionalidad sobre circuitos con un número reducido de cúbits, en este proyecto se propone el uso de modelos híbridos asistidos por la selección de características. Con este propósito se ha desarrollado un marco de experimentación que integra la creación de un modelo híbrido clásico-cuántico de forma parametrizable, permitiendo la ejecución de lotes de experimentación mediante ficheros de configuración. Usando este entorno de experimentación se ha evaluado el efecto de tres enfoques de reducción (PCA, UMAP y Autoencoders), además de distintas estrategias de codificación cuántica y configuraciones de *feature map* de un modelo VQC, empleando los conjuntos de datos MNIST y FMNIST. Los resultados experimentales demuestran el efecto positivo de la reducción de dimensionalidad aplicada. Esto habilita el procesamiento de conjuntos de datos sobre circuitos reducidos y eficientes, que de otro modo serían prohibitivos en *hardware* cuántico actual.

Palabras clave: Aprendizaje Automático Cuántico, NISQ, Reducción de Dimensionalidad, Clasificador Cuántico Variacional.

Abstract

Quantum computing has been a rapidly growing field in recent years. We are currently in the NISQ era, where quantum computers have a limited number of qubits and are susceptible to noise, which affects the accuracy of the operations performed. Against this context, there is a need to demonstrate the practical viability of quantum machine learning. Therefore, and given the difficulty of encoding high-dimensional datasets on circuits with a limited number of qubits, this project proposes the use of hybrid models assisted by feature selection. To this end, an experimental framework has been developed that integrates the creation of a parameterisable classical-quantum hybrid model, allowing the execution of experimental batches via configuration files. Using this experimental environment, the effect of three reduction approaches (PCA, UMAP and Autoencoders) has been evaluated, along with different quantum encoding strategies and feature map configurations of a VQC model, using the MNIST and FMNIST datasets. The experimental results demonstrate the positive effect of the applied dimensionality reduction, enabling the processing of datasets on reduced and efficient circuits, which would otherwise be prohibitive on current quantum hardware.

Keywords: Quantum Machine Learning, NISQ, Dimensionality Reduction, Variational Quantum Classifier.

Agradecimientos

Gracias a Inma, mi familia y mis tutores.

Índice General

Resumen	1
Abstract	3
Agradecimientos	5
Índice General	7
Índice de Figuras	9
Índice de Tablas	11
1 Introducción	13
1.1 Contexto y motivación	13
1.2 Objetivos	14
1.3 Alcance del estudio y limitaciones	15
1.4 Estructura de la memoria	16
2 Estado del arte y marco teórico	17
2.1 Fundamentos de la computación cuántica	17
2.1.1 El cúbit	19
2.1.2 Sistemas de múltiples cúbits	19
2.1.3 Puertas lógicas cuánticas	20
2.2 Aprendizaje automático cuántico	27
2.2.1 Data encoding	28
2.2.2 Variational Quantum Classifier	29
2.2.3 Modelos híbridos	31
2.3 Reducción de dimensionalidad clásica	32
2.3.1 PCA	32
2.3.2 UMAP	33
2.3.3 Autoencoders	35
3 Metodología y diseño experimental	37
3.1 Arquitectura del modelo propuesto	37
3.1.1 Preprocesamiento y reducción clásica	38
3.1.2 VQC	40

3.2	Conjuntos de datos empleados	43
3.3	Entorno de ejecución y tecnologías empleadas	44
3.4	Métricas de evaluación	45
4	Resultados experimentales	47
4.1	Análisis de resultados de codificación por ángulos	47
4.1.1	Mejores soluciones	47
4.1.2	Análisis por parámetro	49
4.2	Análisis de resultados de codificación por amplitud	55
4.3	Comparación entre técnicas de codificación	57
4.4	Discusión de resultados	59
5	Conclusiones y trabajo futuro	63
5.1	Conclusiones	63
5.2	Trabajo futuro	64
5.3	Valoración personal	65
A	Resultados Completos	67

Índice de Figuras

2.1	Circuito cuántico donde se aplica una puerta Hadamard y C-NOT.	18
2.2	Esfera de Bloch	20
2.3	Efecto de la puerta Pauli-X sobre la esfera de Bloch	21
2.4	Efecto de la puerta Pauli-Y sobre la esfera de Bloch	22
2.5	Efecto de la puerta Pauli-Z sobre la esfera de Bloch	23
2.6	Efecto de la puerta Hadamard sobre la esfera de Bloch.	24
2.7	Circuito cuántico de un C-NOT.	25
2.8	Circuito cuántico de la puerta SWAP.	26
2.9	Descomposición de la puerta SWAP mediante tres operaciones C-NOT consecutivas.	26
2.10	Topología de entrelazamiento lineal (<i>linear</i>) sobre un circuito de 4 cúbits.	27
2.11	Topología de entrelazamiento circular (<i>circular</i>) sobre un circuito de 4 cúbits.	27
2.12	Topología de entrelazamiento completo (<i>full</i>) sobre un circuito de 4 cúbits.	27
2.13	Ansatz RealAmplitudes de tres cúbits, dos repeticiones y entrelazamiento lineal.	30
2.14	Esquema de un Autoencoder	35
3.1	Arquitectura del <i>encoder</i> propuesto.	39
3.2	Arquitectura del <i>decoder</i> propuesto.	40
3.3	Circuito cuántico ZFeatureMap de tres cúbits y dos repeticiones.	41
3.4	Circuito cuántico ZZFeatureMap de tres cúbits, una repetición y entrelazamiento lineal, donde $\phi_{ij} = (\pi - x_i)(\pi - x_j)$	41
3.5	Estructura del Ansatz EfficientSU2 de tres cúbits, una repetición y entrelazamiento lineal.	42
4.1	Boxplot del accuracy por técnica de reducción de dimensionalidad para MNIST01	49
4.2	Boxplot del accuracy por técnica de reducción de dimensionalidad para MNIST36	50
4.3	Boxplot del accuracy por técnica de reducción de dimensionalidad para FMNIST06	50
4.4	Boxplot del accuracy por técnica de reducción de dimensionalidad y número de cúbits para MNIST01	51

4.5	Boxplot del accuracy por técnica de reducción de dimensionalidad y número de cúbits para MNIST36	52
4.6	Boxplot del accuracy por técnica de reducción de dimensionalidad y número de cúbits para FMNIST06	52
4.7	Heatmap mostrando el efecto del <i>Feature Map</i> empleado en MNIST01	53
4.8	Heatmap mostrando el efecto del <i>Feature Map</i> empleado en MNIST36	54
4.9	Heatmap mostrando el efecto del <i>Feature Map</i> empleado en FMNIST06	55
4.10	Estudio ablación del efecto del Ansatz en codificación por amplitudes	56
4.11	Comparativa de rendimiento y tiempo de ejecución de las estrategias de codificación. MNIST01	58
4.12	Comparativa de rendimiento y tiempo de ejecución de las estrategias de codificación. MNIST36	58
4.13	Comparativa de rendimiento y tiempo de ejecución de las estrategias de codificación. FMNIST06	59

Índice de Tablas

4.1	Mejores configuraciones obtenidas para cada conjunto de datos, ordenadas por accuracy descendente y tiempo ascendente.	48
4.2	Resultados detallados del estudio de ablación sobre codificación por amplitud incluyendo métricas temporales y estructurales.	56
A.1	Rendimiento relativo según la técnica de reducción de dimensionalidad.	68
A.2	Rendimiento relativo según el <i>feature map</i>	69
A.3	Rendimiento relativo según la dimensionalidad del circuito.	70
A.4	Rendimiento bruto según la técnica de reducción de dimensionalidad.	71

1

Introducción

1.1 Contexto y motivación

La Computación Cuántica (o *Quantum Computing*, QC) es un área de trabajo en auge en los últimos años [9]. En estos sistemas se aprovechan fenómenos como la superposición y el entrelazamiento para procesar información de formas que un ordenador clásico no puede. En los sistemas cuánticos a dos estados, la unidad básica es el cúbit, que puede representar simultáneamente los valores 0 y 1. El modelo de QC más extendido es el basado en puertas cuánticas, donde operaciones unitarias controladas manipulan el estado de los cúbits, componiendo algoritmos que explotan estas propiedades cuánticas. Actualmente nos encontramos en la era *Noisy-Intermediate Scale Quantum* o NISQ de la computación cuántica. En ella los ordenadores cuánticos tienen un número reducido de cúbits y son susceptibles al ruido de fondo proveniente de diversas fuentes que afectan a la precisión de las operaciones realizadas. Este suceso impone restricciones en cuanto a la posibilidad de construir circuitos cuánticos con suficiente complejidad para ser capaces de resolver tareas que requieren cálculos rápidos y precisos. Los ordenadores cuánticos universales (los basados en el paradigma de puertas) actuales son capaces de manejar de media un orden de 156 cúbits [4].

Uno de los campos donde la computación cuántica puede aportar mucho es el Aprendizaje Automático Cuántico (o *Quantum Machine Learning*, QML). Este campo representa un ámbito muy prometedor en la investigación de la física contemporánea y la informática, con aplicaciones de gran alcance en múltiples dominios tales como la química cuántica, inteligencia artificial o incluso física de partículas [16]. Sin embargo, la naturaleza NISQ de las máquinas cuánticas impone muchas restricciones a los avances y factibilidad de QML. Por lo cual, la motivación central de este proyecto reside en la necesidad de tender un puente entre el potencial teórico del QML y su viabilidad práctica en la era NISQ. En este sentido, el enfoque se centra en la dificultad de representar datos clásicos complejos

en máquinas cuánticas limitadas, suponiendo un obstáculo en la posible aplicación/aceleración de muchos métodos QML supervisados y no supervisados, además de limitar el alcance de comparativas de benchmarking que pueden realizarse de forma experimental. El elevado número de características que suelen tener los conjuntos de datos reales supone un impedimento para los circuitos de codificación cuántica (*Quantum Feature Map* [16]), usándose habitualmente un subconjunto de las características disponibles.

Este Trabajo de Fin de Máster se centra en la aplicación de un enfoque híbrido clásico-cuántico, aplicando estrategias de reducción de características clásicas que reduzcan eficazmente la dimensionalidad sin pérdida significativa de información, necesitando un menor número de cúbits y puertas cuánticas.

1.2 Objetivos

El objetivo principal de este Trabajo de Fin de Máster es investigar, implementar y evaluar el impacto de técnicas de reducción de dimensionalidad en el rendimiento y viabilidad de los modelos de Aprendizaje Automático Cuántico, en el contexto de las severas limitaciones de hardware de la era NISQ.

Para abordar ese objetivo se plantean los siguientes objetivos específicos:

- **Investigar el estado del arte:** realizar una investigación sistemática y detallada del estado del arte en la aplicación práctica de diferentes técnicas de aprendizaje automático cuántico. Concretamente, se plantea estudiar los Clasificadores Cuánticos Variacionales [15], identificando sus desafíos de escalabilidad.
- **Integrar técnicas clásicas de preprocesamiento:** revisar e integrar técnicas de reducción de la dimensionalidad clásicas.
- **Implementación de modelos híbridos:** implementar modelos VQC de forma híbrida (preprocesamiento clásico junto con circuito cuántico) haciendo uso del *framework* Qiskit [2] y validar su funcionamiento sobre conjuntos de datos reducidos.
- **Evaluación del rendimiento y análisis de viabilidad:** evaluar y comparar el rendimiento de los modelos híbridos en conjuntos de datos de alta dimensionalidad. Analizar el impacto de la aplicación de este tipo de técnicas en los requerimientos de hardware cuántico (número de

cúbits y profundidad de los circuitos), demostrando la posible viabilidad de aplicar estos modelos dentro de las limitaciones de la era NISQ.

1.3 Alcance del estudio y limitaciones

El alcance del proyecto abarca la implementación y evaluación de modelos VQC híbridos, enfocándose principalmente en las etapas de preprocesamiento y codificación cuántica.

El desarrollo del estudio está sujeto a una serie de limitaciones técnicas y metodológicas que condicionan el marco de experimentación:

- **Simulación clásica del hardware cuántico.** La totalidad de los experimentos cuánticos han sido ejecutados mediante simulación en hardware clásico local (CPU AMD Ryzen 9 7845HX). Esto impone una barrera estricta sobre el número de cúbits a evaluar, dado que el coste en memoria y tiempo de computación crece de manera exponencial con cada cúbit adicional.
- **Restricciones en la explosión combinatoria.** Ante el elevado número de hiperparámetros involucrados en la definición del modelo híbrido (técnicas de reducción, dimensionalidad, configuración del *feature map* y *ansatz*) evaluado sobre distintos conjuntos de datos de dificultad variable, la explosión combinatoria unida al extenso tiempo de simulación restringen el alcance de la experimentación. Se ha tomado la decisión de centrar el estudio principalmente en el preprocesamiento y codificación cuántica, analizando su efecto sobre el rendimiento y viabilidad en la era NISQ.
- **Ausencia de significancia estadística por restricciones temporales.** Dadas las limitaciones de hardware y los extensos tiempos de simulación previamente expuestos, el diseño experimental se ha estructurado primando la exploración de configuraciones a costa de limitar la replicación. Por este motivo, cada configuración de parámetros ha sido ejecutada una única vez. Esto introduce una componente de variabilidad aleatoria propia del proceso de optimización que no ha podido ser mitigada en este estudio, pudiendo introducir ligeras fluctuaciones en los resultados observados.

1.4 Estructura de la memoria

La memoria se estructura en los capítulos que se describen a continuación:

- **Capítulo 1: Introducción.** En este capítulo se establece el marco inicial de trabajo, definiendo el contexto tecnológico y la motivación detrás de este proyecto. Se delimitan los objetivos, así como el alcance del estudio, las limitaciones metodológicas y la organización de la memoria.
- **Capítulo 2: Estado del arte y marco teórico.** Se introducen los fundamentos físicos indispensables de la computación cuántica, el Aprendizaje Automático Cuántico, los desafíos de la era NISQ y las técnicas de reducción de dimensionalidad clásica.
- **Capítulo 3: Metodología y diseño experimental.** Se detalla el diseño arquitectónico de los modelos cuánticos e híbridos propuestos. Se describe el preprocesamiento aplicado, los hiperparámetros de los circuitos cuánticos y el entorno de experimentación.
- **Capítulo 4: Resultados experimentales.** Se exponen los resultados experimentales obtenidos mediante las distintas baterías de pruebas. Se evalúa el efecto de los distintos componentes en el rendimiento obtenido, contrastándolo con su viabilidad ante las restricciones impuestas por el hardware disponible en la era NISQ.
- **Capítulo 5: Conclusiones y trabajo futuro.** Se presentan las conclusiones alcanzadas tras el desarrollo del proyecto, proponiendo diversas líneas que abordar para expandir el alcance del mismo.
- **Anexo A: Resultados Completos.** En el anexo se incluyen la totalidad de los resultados experimentales obtenidos, sobre los que se ha basado el análisis realizado en el Capítulo 4.

Esta estructura sigue un orden lógico, presentando en primer lugar los fundamentos necesarios para comprender el problema, para llegar progresivamente hasta la evaluación de la experimentación y las conclusiones finales obtenidas dentro del marco tecnológico actual.

2

Estado del arte y marco teórico

En este capítulo se sentarán las bases de la computación cuántica, necesarias para comprender los elementos que conforman los modelos de aprendizaje automático cuántico. Se abordan también las técnicas existentes de codificación de datos cuánticos, pilar central de este trabajo, junto con técnicas de reducción de dimensionalidad clásicas.

2.1 Fundamentos de la computación cuántica

La computación clásica se fundamenta en el procesamiento de información mediante circuitos electrónicos cuyo comportamiento puede describirse a través de leyes físicas a nivel macroscópico. Cuando el procesamiento de la información se traslada a una escala microscópica, empleando electrones, fotones o átomos, se observan comportamientos alejados de la intuición clásica para los que es necesario un marco matemático distinto: la mecánica cuántica. Un ordenador cuántico sería por tanto aquel cuyos cálculos se rigen por las leyes de la física cuántica.

Aunque hay varios paradigmas para usar la computación cuántica, el más utilizado es el basado en puertas por su universalidad. En este nuevo paradigma los algoritmos son formulados mediante circuitos. En ellos, la unidad fundamental de información sería el cúbit, contraparte cuántica del bit clásico. Sobre él se aplican puertas lógicas cuánticas para ejecutar operaciones computacionales. A continuación, en la Figura 2.1, se muestra un ejemplo de circuito cuántico. Las puertas mostradas se explicarán en la sección 2.1.3.




Figura 2.1. Circuito cuántico donde se aplica una puerta Hadamard y C-NOT.

El desarrollo de hardware cuántico funcional supone uno de los mayores retos de ingeniería de la actualidad. El propósito es conseguir ordenadores capaces de conservar la coherencia cuántica del sistema, es decir, la capacidad de mantener el estado de superposición y fase cuántica, durante el mayor número de operaciones posible. Los estados cuánticos son muy sensibles a perturbaciones externas, que provocan la decoherencia del sistema perdiendo sus propiedades cuánticas, lo cual afecta a la información almacenada en ellos que es degradada a un estado clásico. Por este motivo los protocolos de corrección de errores son críticos. Sin embargo, los métodos actuales conllevan un sobre coste elevado en cuanto a la cantidad de cúbits necesarios, por lo que mitigar este efecto sigue suponiendo un reto a largo plazo.

En los últimos años, se han realizado enormes esfuerzos para poder llevar aplicaciones cuánticas al mercado, redirigiendo las investigaciones realizadas en este ámbito. Desde unos inicios puramente académicos, a las numerosas start-ups y grandes compañías tecnológicas (D-Wave, IBM).

Se han logrado notables progresos a nivel de hardware cuántico hasta alcanzar la era actual NISQ (*Noisy Intermediate-Scale Quantum*). Este término, acuñado por John Preskill [13], engloba a los primeros prototipos de lo que un día será un ordenador cuántico completo. Estos dispositivos cuánticos se caracterizan por poseer una cantidad de cúbits limitada a unos cientos y con tasas de error elevadas en puertas lógicas de dos cúbits.

Las características de los dispositivos NISQ limitan considerablemente la profundidad y el número de cúbits que pueden ser empleados en el diseño de algoritmos. En este contexto la profundidad se refiere al número necesario de capas para aplicar todas las puertas cuánticas del circuito, ejecutando en paralelo aquellas que actúen sobre cúbits distintos. A mayor profundidad, mayor tiempo de ejecución es necesario para completar el circuito, aumentando el riesgo de que el ruido externo provoque la decoherencia del sistema.

La comunidad científica persigue el objetivo de conseguir aplicaciones prácticas adaptadas a las limitaciones del hardware actual que permitan demostrar la ventaja cuántica que ofrecen los ordenadores cuánticos. En este contexto, la resolución de problemas de optimización y el aprendizaje automático cuántico destacan como dos de las áreas más prometedoras.

2.1.1 El cúbit

En la computación clásica, el bit es la unidad fundamental de representación de información. Este únicamente puede encontrarse en dos estados, 0 o 1, representando un dígito del sistema de numeración binario.

La computación cuántica tiene como elemento análogo el cúbit. El cúbit a su vez puede encontrarse en dos posibles estados, $|0\rangle$ o $|1\rangle$, equivalentes a su contraparte clásica. La diferencia por tanto del cúbit, es la posibilidad de encontrarse en un estado distinto a $|0\rangle$ o $|1\rangle$. Estos estados intermedios son lo que se conoce como superposición cuántica, una combinación lineal de los estados base:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle. \quad (2.1)$$

Un cúbit estaría representado por un vector dentro de un espacio bidimensional, siendo α y β números complejos.

Así como en computación clásica se examina el estado de un bit para determinar si se encuentra en el estado 0 o 1, en computación cuántica es imposible examinar un cúbit para determinar su estado cuántico (i.e., α y β). En su lugar obtendremos el estado 0 con una probabilidad $|\alpha|^2$, o el estado 1 con una probabilidad $|\beta|^2$, de forma que $|\alpha|^2 + |\beta|^2 = 1$. Esta propiedad de normalización permite reformular el estado del cúbit como:

$$|\psi\rangle = \cos \frac{\theta}{2} |0\rangle + e^{i\varphi} \sin \frac{\theta}{2} |1\rangle \quad (2.2)$$

Ahora θ y φ definen un punto en una esfera unidad, también conocida como la esfera de Bloch (véase la Figura 2.2).

2.1.2 Sistemas de múltiples cúbits

En computación clásica, dos bits permiten representar cuatro estados diferentes. Asimismo sucedería en un sistema cuántico de dos cúbits, formado por las bases: $|00\rangle, |01\rangle, |10\rangle, |11\rangle$. Este sistema también puede encontrarse en superposición, de forma que cada estado llevará asociado un coeficiente complejo llamado amplitud. Dicho estado se representaría como

$$|\psi\rangle = \alpha_{00}|00\rangle + \alpha_{01}|01\rangle + \alpha_{10}|10\rangle + \alpha_{11}|11\rangle \quad (2.3)$$

La probabilidad por tanto de realizar una medición y obtener el estado $|x\rangle$ será de $|\alpha_x|^2$. Las amplitudes deben de cumplir la condición de normalización $\sum_{x \in \{0,1\}^2} |\alpha_x|^2 = 1$.




Figura 2.2. Esfera de Bloch

De forma general, los estados de la base computacional de un sistema de n cúbits tendrán la forma $|x_1x_2...x_n\rangle$, estando definido un estado cuántico por 2^n amplitudes.

2.1.3 Puertas lógicas cuánticas

En esta sección se explican algunas puertas lógicas cuánticas necesarias en la construcción de los circuitos cuánticos empleados en este proyecto.

Así como se puede representar vectorialmente el estado de un cúbit $|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$, como

$$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \quad (2.4)$$

las puertas lógicas cuánticas son representadas mediante matrices. A continuación se presenta la puerta NOT como ejemplo:

$$X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad (2.5)$$

El efecto que tendría aplicar esta puerta sobre el estado anterior sería el siguiente:

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \beta \\ \alpha \end{bmatrix}, \quad (2.6)$$

obteniendo el nuevo estado $|\psi\rangle = \beta|0\rangle + \alpha|1\rangle$.

Antes se ha mencionado la propiedad de normalización que deben cumplir las amplitudes de un estado cuántico $|\psi\rangle$ dado. Esta propiedad debe mantenerse para un estado $|\psi'\rangle = \alpha'|0\rangle + \beta'|1\rangle$ tras haber aplicado una puerta lógica. Una matriz U podrá ser una puerta lógica cuántica válida si es unitaria, es decir, $U^\dagger U = U U^\dagger = I$, donde $U^\dagger$ se trata de la matriz adjunta de U (conjugado de la matriz transpuesta). Si la puerta lógica cumple dicha propiedad, el estado resultante de su aplicación cumplirá la propiedad de normalización.

2.1.3.1 Puertas de un cúbit

A continuación se revisarán algunas puertas lógicas de un cúbit empleadas en la construcción de los circuitos cuánticos que se presentarán en capítulos siguientes.

Pauli-X

La puerta Pauli-X, presentada anteriormente como ejemplo, es la puerta análoga al NOT clásico, siendo su representación matricial:

$$X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}. \quad (2.7)$$

Como se ha observado anteriormente, aplicar la puerta Pauli-X tendría el efecto siguiente

$$X \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \beta \\ \alpha \end{bmatrix}. \quad (2.8)$$

Se habría conseguido intercambiar la amplitud entre los estados $|0\rangle$ y $|1\rangle$. Sobre la esfera de Bloch, el efecto de aplicar esta técnica se visualiza como una rotación de π radianes sobre el eje X (véase la Figura 2.3).




Figura 2.3. Efecto de la puerta Pauli-X sobre la esfera de Bloch

Pauli-Y

La matrix Pauli-Y se representa mediante la siguiente matriz

$$Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix}. \quad (2.9)$$

El resultado de aplicar la puerta Pauli-Y sería:

$$Y \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} i\beta \\ -i\alpha \end{bmatrix}. \quad (2.10)$$

Esta puerta además de invertir la amplitud de las bases computacionales, introduce una fase relativa compleja. Este efecto se puede visualizar sobre la esfera de Bloch como una rotación de π radianes sobre el eje Y (véase la Figura 2.4).




Figura 2.4. Efecto de la puerta Pauli-Y sobre la esfera de Bloch

Pauli-Z

La puerta Pauli-Z, representada matricialmente como

$$Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \quad (2.11)$$

deja el estado base $|0\rangle$ inalterado, mientras que aplicaría una inversión de fase sobre el estado $|1\rangle$, dejando inalteradas las probabilidades de medición de los estados base.

El resultado de aplicar esta puerta sería:

$$Z \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \alpha \\ -\beta \end{bmatrix}. \quad (2.12)$$

En la esfera de Bloch la aplicación de esta puerta se materializa como una rotación de π radianes sobre el eje Z (véase la Figura 2.5).




Figura 2.5. Efecto de la puerta Pauli-Z sobre la esfera de Bloch

Hadamard

La puerta Hadamard se trata de una de las puertas más útiles en computación cuántica. Su función es tomar como entrada un estado $|0\rangle$ y $|1\rangle$, convirtiéndolos en estados $|+\rangle$ y $|-\rangle$ respectivamente. Sobre la esfera de Bloch, estos estados se encuentran sobre el eje X en posiciones opuestas. Son estados de perfecta superposición, teniendo el estado $|-\rangle$ una fase relativa de 180° entre las componentes $|0\rangle$ y $|1\rangle$.

La representación matricial de esta puerta lógica sería


$$H = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad (2.13)$$

siendo el resultado de aplicarla


$$H|\psi\rangle = \alpha \frac{|0\rangle + |1\rangle}{\sqrt{2}} + \beta \frac{|0\rangle - |1\rangle}{\sqrt{2}}. \quad (2.14)$$

Esta puerta cumple además la propiedad $H^2 = I$, por lo que aplicarla dos veces seguidas no tendría ningún efecto sobre el estado inicial.

Sobre la esfera de Bloch, el efecto de la puerta Hadamard se observa como mapear el eje X sobre el eje Z y viceversa (véase la Figura 2.6).



(a) Efecto sobre el estado $|0\rangle$.



(b) Efecto sobre el estado $|1\rangle$.

Figura 2.6. Efecto de la puerta Hadamard sobre la esfera de Bloch.

Puertas de rotación

Otro conjunto de puertas útiles y empleadas en Aprendizaje Automático Cuántico son las de rotación. Estas vienen derivadas de la exponenciación de las matrices Pauli vistas anteriormente dando como resultado las siguientes ecuaciones:

$$R_x(\theta) = e^{-i\theta X/2} = \cos \frac{\theta}{2} I - i \sin \frac{\theta}{2} X = \begin{pmatrix} \cos(\frac{\theta}{2}) & -i \sin(\frac{\theta}{2}) \\ -i \sin(\frac{\theta}{2}) & \cos(\frac{\theta}{2}) \end{pmatrix} \quad (2.15)$$

$$R_y(\theta) = e^{-i\theta Y/2} = \cos \frac{\theta}{2} I - i \sin \frac{\theta}{2} Y = \begin{pmatrix} \cos(\frac{\theta}{2}) & -\sin(\frac{\theta}{2}) \\ \sin(\frac{\theta}{2}) & \cos(\frac{\theta}{2}) \end{pmatrix} \quad (2.16)$$

$$R_z(\theta) = e^{-i\theta Z/2} = \cos \frac{\theta}{2} I - i \sin \frac{\theta}{2} Z = \begin{pmatrix} e^{-i\frac{\theta}{2}} & 0 \\ 0 & e^{i\frac{\theta}{2}} \end{pmatrix} \quad (2.17)$$

El efecto de aplicar una puerta de rotación $R_{\hat{n}}(\theta)$, sobre el estado de un cúbit representado mediante un vector en la esfera de Bloch, sería tal como rotar dicho vector un ángulo θ sobre el eje $\hat{n}$.

2.1.3.2 Puertas de múltiples cúbits

Este tipo de puertas permiten la interacción entre múltiples cúbits, constituyendo el mecanismo fundamental para generar el entrelazamiento cuántico. A pesar de la existencia de mayor variedad de este tipo de operadores, en esta sección se introduce la puerta C-NOT, de gran importancia debido a su propiedad de universalidad y por ser la única puerta aplicada en los circuitos implementados. Se introduce además la puerta SWAP, la cual sirve como ejemplo de la universalidad de la puerta C-NOT.

Controlled-NOT

Esta puerta toma como entrada dos cúbits, llamados de control y objetivo. En un circuito cuántico esta puerta estaría representada tal y como se muestra a continuación




Figura 2.7. Circuito cuántico de un C-NOT.

siendo su representación matricial

$$C\text{-NOT} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}. \quad (2.18)$$

Esta matriz actuará invirtiendo el bit objetivo únicamente si el bit de control se encuentra en estado 1.

$$CNOT|00\rangle = |00\rangle \quad (2.19)$$

$$CNOT|01\rangle = |01\rangle \quad (2.20)$$

$$CNOT|10\rangle = |11\rangle \quad (2.21)$$

$$CNOT|11\rangle = |10\rangle \quad (2.22)$$

La puerta C-NOT se comporta como una puerta XOR clásica entre el cúbit de control y objetivo, almacenando el resultado en este último cúbit.

Cabe recalcar la propiedad de universalidad que cumple la puerta C-NOT junto con las puertas de un único cúbit. Cualquier puerta lógica de múltiples cúbits puede ser construida mediante el uso únicamente de puertas C-NOT y puertas de un solo cúbit.

A continuación se introduce la puerta SWAP, mostrando a su vez como se puede aplicar empleando únicamente puertas C-NOT.

Puerta SWAP

La puerta SWAP es una operación sobre dos cúbits cuyo propósito es intercambiar sus estados. En un circuito cuántico esta puerta se representaría como




Figura 2.8. Circuito cuántico de la puerta SWAP.

siendo su representación matricial

$$\text{SWAP} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}. \quad (2.23)$$

El efecto de aplicar esta puerta dado las combinaciones de estados base posibles sería

$$\text{SWAP}|00\rangle = |00\rangle \quad (2.24)$$

$$\text{SWAP}|01\rangle = |10\rangle \quad (2.25)$$

$$\text{SWAP}|10\rangle = |01\rangle \quad (2.26)$$

$$\text{SWAP}|11\rangle = |11\rangle \quad (2.27)$$

Esta puerta puede ser construida empleando tres puertas C-NOT dispuestas tal y como se muestra a continuación:




Figura 2.9. Descomposición de la puerta SWAP mediante tres operaciones C-NOT consecutivas.

Tipos de entrelazamiento

Una vez introducidas algunas puertas de múltiples cúbits, empleadas en la generación del entrelazamiento cuántico, se muestran a continuación distintas estrategias de entrelazamiento, las cuales difieren en la disposición geométrica de las puertas.

Lineal Esta estrategia genera entrelazamiento entre el cúbit i con el cúbit $i + 1$, para todo $i \in \{0, 1, \dots, n - 2\}$, tal y como puede apreciarse en la Figura 2.10.




Figura 2.10. Topología de entrelazamiento lineal (*linear*) sobre un circuito de 4 cúbits.

Circular El entrelazamiento circular aplica entrelazamiento lineal añadiendo un entrelazamiento adicional entre el primer y último cúbit antes de la sección lineal, como se ve en la Figura 2.11.




Figura 2.11. Topología de entrelazamiento circular (*circular*) sobre un circuito de 4 cúbits.

Completo En el entrelazamiento completo, todo cúbit se encuentra entrelazado con todos los demás, como se muestra en la Figura 2.12.




Figura 2.12. Topología de entrelazamiento completo (*full*) sobre un circuito de 4 cúbits.

2.2 Aprendizaje automático cuántico

El aprendizaje automático se sitúa en la intersección entre la informática, las matemáticas y la estadística. El objetivo es dotar a las máquinas de la capacidad de resolver tareas cognitivas (como el reconocimiento de imágenes o procesamiento del lenguaje) basándose en el aprendizaje de patrones subyacentes en los datos.

Propuestas de combinar el aprendizaje automático junto con la computación cuántica han ido surgiendo desde los comienzos de la computación cuántica en la década de los años 80. De 2014 en adelante, el interés en esta disciplina ha ido en aumento, con una literatura en constante crecimiento tratando de unir ambas disciplinas.

En esta sección se introduce el modelo de clasificación cuántico empleado. La sección se estructura en tres partes: métodos de codificación de información clásica, estructura y optimización de los Clasificadores Cuánticos Variacionales, y su integración en arquitecturas híbridas clásico-cuánticas.

2.2.1 Data encoding

Para lograr que un ordenador cuántico sea capaz de aprender a partir de datos clásicos, se debe representar la información mediante estados cuánticos. En aprendizaje automático cuántico, la etapa de preparación del estado cuántico es crucial, y frecuentemente supone un cuello de botella en el tiempo de ejecución. El proceso de codificación se interpreta como emplear un *feature map* que mapea el dato de entrada clásico en el espacio de Hilbert del sistema cuántico. El *feature map* escogido determinará la estructura del espacio de características, de modo que el circuito adecuado es capaz de separar datos de diferentes clases, resolviendo el problema de aprendizaje, de forma similar a los métodos de *kernel* empleados en aprendizaje cuántico clásico.

Se presentan a continuación los dos métodos de codificación cuántica probados en este proyecto: codificación por ángulos (*Angle Encoding*) y codificación por amplitud (*Amplitude Encoding*).

2.2.1.1 Angle Encoding

Un escalar puede ser asociado con el parámetro temporal t a la hora de implementar una transformación unitaria $U(t) = e^{-itH}$ definida por un hamiltoniano H . Basándose en este principio, la codificación por ángulos emplea puertas de rotación de Pauli para codificar cada característica del vector de datos clásico mediante el ángulo de rotación aplicado sobre cada cúbit. En su versión más sencilla, se aplicaría una puerta de rotación R parametrizada por cada componente del vector de características $x = (x_1, x_2, \dots, x_N)$, normalizado habitualmente en un intervalo acotado por 2π :

$$U(x) = R(x_1) \otimes \dots \otimes R(x_N). \quad (2.28)$$

Los circuitos empleados en codificación por ángulos pueden estructurarse mediante secuencias que combinan puertas de rotación parametrizadas por los datos de entrada junto con puertas de superposición y entrelazamiento, típicamente Hadamard o CNOT, permitiendo construir *feature maps*

más complejos.

Esta estrategia de codificación es una de las más robustas y ampliamente utilizadas en el paradigma de los circuitos cuánticos variacionales. Esto se debe a mantener una profundidad reducida y constante, ideal bajo el contexto y restricciones de la era NISQ. Sin embargo, presenta el inconveniente de necesitar tantos cúbits como parámetros de entrada tiene el modelo de aprendizaje automático, lo que vuelve prohibitivo su uso con conjuntos de datos de alta dimensionalidad.

2.2.1.2 Amplitude Encoding

La codificación por amplitud mapea un vector real o complejo $x \in \mathbb{C}^N$ sobre las amplitudes del estado cuántico

$$|\psi_x\rangle = \sum_{i=0}^{N-1} x_i |i\rangle. \quad (2.29)$$

Esta representación necesita que el vector x se encuentre normalizado de forma que cumpla $\sum_i |x_i|^2 = 1$, y con un *padding* tal que N sea potencia de 2. Esta técnica permite codificar conjuntos de datos completos en superposición, pero no ha sido abordada en este proyecto.

La ventaja de esta técnica es que tan solo se requieren $n = \log N$ cúbits para codificar un vector de entrada de N características. Sin embargo, la preparación de las amplitudes del estado cuántico es una tarea compleja, que requiere generalmente de circuitos cuánticos cuya profundidad crece exponencialmente con el número de cúbits. Para la implementación en hardware real de clasificadores cuánticos, esta restricción puede resultar prohibitiva debido a la acumulación de errores y decoherencia propia de la era NISQ.

2.2.2 Variational Quantum Classifier

Una vez se ha introducido cómo se puede codificar información clásica en un circuito cuántico, se debe abordar cómo obtener un modelo que sea capaz de emplear dicha información para resolver el problema en cuestión.

Para explicar en que consiste un *Variational Quantum Classifier* (VQC), primero se debe explicar lo qué es un *Variational Quantum Algorithm* [14, Sec. 3.6.5]. Este tipo de algoritmos se encuentran definidos por un *ansatz*, un patrón que define qué puertas son aplicadas a qué cúbits. El *ansatz* define una plantilla que puede ser aplicada repetidas veces y sobre un número variable de cúbits. El término *variational* se debe a la parametrización ajustable que es aplicada sobre algunas de las puertas que componen el *ansatz*, típicamente puertas de rotación Pauli vistas en la sección 2.1.3.1. Estos parámetros pueden ser ajustados mediante un algoritmo clásico de optimización, de forma similar a cómo se

realiza el entrenamiento de una red neuronal. En la Figura 2.13, se puede observar un ejemplo de *ansatz* llamado *RealAmplitudes*.




Figura 2.13. Ansatz *RealAmplitudes* de tres cúbits, dos repeticiones y entrelazamiento lineal.

Un VQC es una clase de algoritmo dentro de los *Variational Quantum Algorithm*. Está compuesto por un *feature map*, encargado de codificar la información clásica en el estado cuántico; seguido de un *ansatz* tras el que se aplica la medición. Los parámetros del circuito se someten a un proceso de optimización híbrido.

Habiendo ya introducido los elementos que conforman el circuito hasta llegar a un estado cuántico final, queda explicar cómo se extrae dicho estado de forma que sea interpretable en términos de clasificación clásica. Para ello se aplica una operación de medición sobre la base computacional, mediante el observable Pauli-Z,

$$\sigma_z = |0\rangle\langle 0| - |1\rangle\langle 1|, \quad (2.30)$$

permitiendo leer +1 en el caso de observar $|0\rangle$, o -1 correspondiente a $|1\rangle$. Aplicar mediciones separadas sobre distintos cúbits permite obtener una cadena binaria (*bitstring*) de longitud n , siendo n el número de cúbits, con una distribución de probabilidad determinada por el estado cuántico. Generalmente, los *bitstrings* son mapeados sobre las clases del problema de clasificación, asociando su probabilidad correspondiente a la clase.

Se ha mencionado la probabilidad de medir un *bitstring*, y es que, como se introdujo en la sección 2.1.1, el resultado de medir un cúbit que se encuentra en estado de superposición no es determinista. Por ello, para obtener una aproximación del estado real se deben realizar múltiples mediciones. La cantidad de mediciones a realizar, también llamadas *shots* dependerá del margen de error que se esté dispuesto a asumir.

Finalmente se aborda cómo entrenar estos modelos. Uno de los métodos más frecuentemente utilizados es la diferenciación automática [14, Sec. 5.3]. Dada la implementación programática de una función derivable f_θ , se proporcionan métodos para calcular las derivadas parciales de la forma $\partial_\mu f_\theta$. Este mismo método es el aplicado en el cálculo de la propagación hacia atrás empleada en el

entrenamiento de redes neuronales.

Este método se basa en la aplicación de la regla de la cadena. Considerando la función de coste $C(\theta)$ que evalúa el modelo f dependiente de los parámetros θ , la derivada parcial $\partial_\mu C$ con respecto de $\mu \in \theta$ puede escribirse como

$$\partial_\mu C(\theta) = \frac{\partial C}{\partial f_\theta} \frac{\partial f_\theta}{\partial \mu}. \quad (2.31)$$

En el entrenamiento del VQC, el cálculo de $\frac{\partial C}{\partial f_\theta}$ puede realizarse por librerías que implementan la diferenciación automática de forma clásica. Sin embargo, f_θ es el resultado del circuito cuántico. Por este motivo se debe emplear un método para calcular la derivada parcial de un circuito cuántico parametrizado con respecto a sus propios parámetros variacionales.

El método *parameter-shift rule*, es el empleado en el cálculo de las derivadas parciales. Esta técnica establece que la derivada parcial del valor esperado de f_μ se puede calcular como la combinación lineal de la misma función evaluada en puntos donde el parámetro μ ha sido desplazado.

A pesar de que el método anterior hace posible la optimización de los VQC mediante métodos de aprendizaje profundo, existe el problema conocido como *barren plateaus*. Este problema plantea la existencia de zonas del espacio de la función de coste donde los gradientes se desvanecen tendiendo a valores cercanos a cero. Esto provoca un entrenamiento lento y costoso, que además incrementa la precisión con la que se debe realizar la medición cuántica con el objetivo de distinguir señales de gradiente pequeñas. Este suceso suele darse cuando el *ansatz* empleado es muy expresivo y en grandes espacios de Hilbert.

Cabe destacar que el impacto de los *barren plateaus* no se limita únicamente a métodos de optimización basados en gradientes. Otros algoritmos de optimización libres de gradientes, como el popular optimizador COBYLA empleado en el entrenamiento de modelos cuánticos, tampoco se encuentran exentos de sufrir este problema, tal y como demuestra el artículo de Arrasmith [1].

2.2.3 Modelos híbridos

A pesar de que el propio bucle de optimización del VQC le confiere ya un estatus de modelo híbrido clásico-cuántico, el concepto de hibridación también puede ser extendido al proceso de *data encoding*. En este contexto, la preparación del estado cuántico inicial no dependerá únicamente del *feature map* escogido, sino de su combinación con el preprocesamiento previo aplicado sobre el conjunto de datos.

En este proyecto se explora la aplicación de técnicas de reducción de dimensionalidad clásicas como componente adicional de la preparación del estado cuántico. El uso de este tipo de modelos

híbridos abre la posibilidad de abordar conjuntos de datos voluminosos de manera efectiva mediante circuitos con un número de cúbits reducido, ajustándose a las restricciones NISQ actuales a la vez que se reduce el riesgo de sufrir *barren plateaus*, altamente influenciado por espacios de Hilbert mayores.

2.3 Reducción de dimensionalidad clásica

Tal y como se ha introducido en la sección anterior, los circuitos cuánticos se encuentran altamente limitados en cuanto al número de cúbits disponibles. Para procesar conjuntos de datos de alta dimensionalidad resulta imperativo reducir el conjunto de características inicial a un espacio latente que mantenga la mayor cantidad de información posible.

Con este propósito, se evalúan e introducen a continuación tres métodos de reducción de dimensionalidad [3]: PCA, UMAP y autoencoders. Esta selección viene motivada por el deseo de probar un método de cada una de las tres categorías principales de métodos de reducción de características.

- **PCA:** Por ser un método clásico de reducción lineal dentro de la categoría de métodos espectrales.
- **UMAP:** Método novedoso de reducción no lineal basada en vecindarios dentro de la categoría de métodos probabilísticos. Conformar el estado del arte junto con t-SNE de métodos de visualización.
- **Autoencoder:** Perteneciente a la categoría de métodos de reducción basados en redes neuronales.

2.3.1 PCA

PCA (*Principal Component Analysis*) se trata de una técnica ampliamente conocida y utilizada como método de reducción de características. Esta técnica fue propuesta inicialmente por Pearson en 1901 [10]. Posteriormente se propuso Kernel PCA, capaz de solventar la estricta linealidad de PCA y aprender estructuras no lineales.

El propósito principal de esta técnica es reducir la dimensionalidad preservando la mayor cantidad de varianza presente en el conjunto de datos como sea posible. Para ello se construye un nuevo subconjunto de variables conocidas como componentes principales, sin correlación entre sí y ordenadas de forma que las primeras retienen la mayor parte de la varianza presente en el conjunto de datos.

Funcionamiento

Supongamos un vector x formado por p variables, siendo la varianza de las p características y la correlación existente entre ellas de interés. Únicamente ante un problema reducido podría ser útil comprobar cada varianza y las $\frac{1}{2}p(p-1)$ correlaciones existentes. PCA aborda este problema ofreciendo un conjunto reducido de variables derivadas de los datos que preserven la mayor información.

Siguiendo el desarrollo formal propuesto por Jolliffe [6], el primer paso sería encontrar una función lineal $\alpha'_1 x$ teniendo los elementos de x máxima varianza, donde α_1 es un vector de p constantes y $'$ denota transposición, de forma que

$$\alpha'_1 x = \alpha_{11}x_1 + \alpha_{12}x_2 + \dots + \alpha_{1p}x_p = \sum_{j=1}^p \alpha_{1j}x_j \quad (2.32)$$

El siguiente paso sería encontrar $\alpha'_2 x$ no correlacionada con $\alpha'_1 x$ y con máxima varianza, así hasta llegar al paso k -ésimo donde una función $\alpha'_k x$ tiene máxima varianza sin estar correlacionado a $\alpha'_1 x, \alpha'_2 x, \dots, \alpha'_{k-1} x$. Cada una de estas $\alpha'_k x$ serían las componentes principales, pudiendo llegar hasta p componentes, habiéndose logrado capturar la mayor parte de la varianza por m componentes principales siendo $m \ll p$.

Conociendo ya el concepto de componente principal, queda definir como obtenerlas. Para ello es necesaria la matriz de covarianza Σ . Esta matriz para $i \neq j$, tendrá como su elemento (i, j) la covarianza entre el i -ésimo y j -ésimo elemento de x . Asimismo cuando $i = j$, se tendrá la varianza del elemento j . Para $k = 1, 2, \dots, p$, la k -ésima componente principal vendrá dada por $z_k = \alpha'_k x$ donde α_k es el autovector de Σ correspondiente al k -ésimo mayor autovalor λ_k .

2.3.2 UMAP

UMAP (*Uniform Manifold Approximation and Projection for Dimension Reduction*) [8] es una técnica de reducción de dimensionalidad recientemente propuesta. Se trata de un algoritmo dentro de la familia de aprendizaje basado en grafos de k -vecinos más cercanos, como t-SNE.

Funcionamiento

El funcionamiento del algoritmo se divide en dos fases: la construcción del grafo y la optimización de su disposición en el espacio de baja dimensionalidad.

La primera fase trata de construir un grafo ponderado de k -vecinos. Dado el conjunto de datos

$X = \{x_1, \dots, x_N\}$, junto a una métrica de disimilitud $d : X \times X \rightarrow \mathbb{R}_{\geq 0}$, y un hiperparámetro k , se construye el conjunto $\{x_{i_1}, \dots, x_{i_k}\}$ de los k vecinos más cercanos de x_i bajo la métrica d .

Para cada x_i se define un ρ_i tal que

$$\rho_i = \min\{d(x_i, x_{i_j}) \mid 1 \leq j \leq k, d(x_i, x_{i_j}) > 0\}, \quad (2.33)$$

y un σ_i que cumpla con la condición

$$\sum_{j=1}^k \exp\left(\frac{-\max(0, d(x_i, x_{i_j}) - \rho_i)}{\sigma_i}\right) = \log_2(k). \quad (2.34)$$

La selección de ρ_i asegura que x_i conecte con al menos un vecino con una arista de peso 1. A nivel práctico mejora la representación en conjuntos de alta dimensionalidad mientras que otros algoritmos, como t-SNE comienzan a sufrir la maldición de dimensionalidad. La selección de σ_i actúa como un factor de normalización.

Se puede entonces definir un grafo dirigido ponderado $\bar{G} = (V, E, w)$, donde los vértices V se corresponden al conjunto X . El conjunto de aristas dirigidas vendría dado por $E = \{(x_i, x_{i_j}) \mid 1 \leq j \leq k, 1 \leq i \leq N\}$, definiéndose el peso w como:

$$w((x_i, x_{i_j})) = \exp\left(\frac{-\max(0, d(x_i, x_{i_j}) - \rho_i)}{\sigma_i}\right). \quad (2.35)$$

Para un punto dado x_i , existe un grafo inducido por x_i y un conjunto de aristas salientes que inciden x_i . Además, intuitivamente se puede interpretar el peso w de una arista en este grafo local dirigido como la probabilidad de que la misma exista. Dado el conjunto de grafos locales, representados como que un grafo dirigido $\bar{G}$ no simétrico, se deben combinar en una representación topológica unificada.

Para ello, dada la matriz de adyacencia ponderada A de $\bar{G}$, se puede obtener la matriz simétrica

$$B = A + A^T - A \circ A^T, \quad (2.36)$$

donde $\circ$ es el producto Hadamard.

Interpretando A_{ij} como la probabilidad de que la arista dirigida entre x_i y x_j exista, entonces B_{ij} es la probabilidad de que al menos una de las dos aristas dirigidas exista. Este método de construcción del grafo permite capturar la estructura geométrica de los datos de manera fiel.

Distribución del grafo

UMAP emplea un algoritmo de disposición de grafos dirigidos basado en fuerzas en un espacio de baja dimensionalidad. Un grafo distribuido por fuerzas emplea fuerzas de atracción sobre aristas y

fuerzas repulsivas aplicadas sobre vértices. El algoritmo aplica de forma iterativa estas fuerzas de atracción y repulsión, garantizando la convergencia a un mínimo local si se reducen lentamente las fuerzas de atracción y repulsión aplicadas, de forma similar a técnicas de temple simulado.

Se busca obtener un grafo H formado por los puntos $\{y_i\}_{i=1,\dots,N}$, equivalente al grafo ponderado G . Es decir, que el grafo ponderado inducido por los puntos y_i , sea lo más similar posible al grafo $\bar{G}$ medido por la entropía cruzada entre las probabilidades de las aristas.

2.3.3 Autoencoders

Un autoencoder [3, Sec. 19.2] es un modelo formado por un *encoder* $E(\cdot)$ y un *decoder* $D(\cdot)$. Existen distintos tipos de autoencoders, pero todos ellos aprenden una codificación latente situada entre el *encoder* y el *decoder*. Los autoencoders inferenciales, como los *variational autoencoder* (VAE) o los *adversarial autoencoders* (AAE), aprenden una codificación en espacio latente estocástico. Los reconstructivos son otro tipo de autoencoders que transforman el dato de entrada en una codificación por el *encoder*. Posteriormente el *decoder* tratará de reconstruir generando de nuevo el dato de entrada. Estos elementos están formados por múltiples capas de redes neuronales.




Figura 2.14. Esquema de un Autoencoder

Los datos de entrada de un autoencoder vienen dados por $x \in \mathbb{R}^d$, donde d es la dimensionalidad de los datos. Los datos reconstruidos por el *decoder* se denota como $\hat{x} \in \mathbb{R}^d$. La representación codificada de los datos, salida del *encoder* y entrada del *decoder*, se define como $f(x) := E(x) \in \mathbb{R}^p$, siendo p la dimensionalidad de la codificación. Se puede decir por tanto que $\hat{x} = D(E(x)) = D(f(x))$.

Cuando $p > d$, estaríamos ante un *overcomplete autoencoder*, mientras que si $p < d$, se trataría de un *undercomplete autoencoder*.

Para el propósito de este proyecto, donde el objetivo es reducir la dimensionalidad de entrada del circuito cuántico, se aplicará un *undercomplete autoencoder*.

El uso de funciones de activación no lineales en las capas del *encoder* y el *decoder* permiten aprender patrones complejos en los datos, consiguiendo una reducción de características no lineal. Esto supone un factor diferenciador clave respecto a PCA, el cual está estrictamente limitado a la búsqueda de hiperplanos lineales.

3

Metodología y diseño experimental

En este capítulo se detalla la metodología experimental adoptada y el diseño arquitectónico de los modelos propuestos, orientados al paradigma de aprendizaje automático cuántico bajo las restricciones de la era NISQ. En primer lugar, la Sección 3.1 presenta la arquitectura del modelo empleada, diferenciando entre el enfoque puramente cuántico y el híbrido clásico-cuántico. A continuación, en la Sección 3.1.1 se describen las técnicas de reducción de dimensionalidad clásicas aplicadas. La Sección 3.1.2 detalla la implementación realizada del Clasificador Cuántico Variacional, especificando las características de sus componentes. Posteriormente, se introducen en la Sección 3.2 los conjuntos de datos empleados durante la experimentación. El entorno de experimentación y las tecnologías empleadas son abordados en la Sección 3.3. Para finalizar, la Sección 3.4 describe las métricas de evaluación recogidas, así como las propiedades de los circuitos cuánticos empleados en el análisis del rendimiento y viabilidad de los modelos en la era NISQ.

3.1 Arquitectura del modelo propuesto

Conocemos las limitaciones de hardware que presentan los ordenadores cuánticos de la era NISQ: circuitos limitados en el número de cúbits, puertas lógicas y profundidad debido al efecto de decoherencia provocado por perturbaciones externas. En este trabajo se pone a prueba el uso de técnicas de reducción de características con el propósito de poder abordar problemas de una relativamente alta dimensionalidad en entornos restringidos.

En la experimentación se han evaluado dos enfoques diferenciados: un modelo puramente cuántico y otro híbrido clásico-cuántico. Para el primero se ha empleado codificación por amplitud (Sección 2.2.1.2), pudiendo codificar un vector de dimensión 2^n empleando únicamente n cúbits. Dado que los conjuntos de datos escogidos (Sección 3.2) constan de 784 dimensiones, estos pueden ser representados por tan solo 10 cúbits, eliminando la necesidad de aplicar una reducción previa de características clásica.

Por otra parte, se ha implementado el enfoque híbrido basado en codificación por ángulos (Sección 2.2.1.1). Esta técnica mapea el valor de cada característica clásica como el ángulo de rotación de una puerta lógica unitaria, representando n características empleando n cúbits. Debido a la restricción del número de cúbits disponibles en la era NISQ, se propone la integración de una capa de reducción de dimensionalidad clásica, condensando la información en un espacio latente compacto y abordable por un circuito compatible con el hardware actual.

3.1.1 Preprocesamiento y reducción clásica

Como se ha comentado debido a las limitaciones en el número de cúbits de los ordenadores cuánticos de la era NISQ, y al elevado número de características que presentan ciertos conjuntos de datos, es necesario comprimir la información clásica antes de ser codificada en el circuito cuántico. Para ello se han probado tres técnicas de reducción de características introducidas en la Sección 2.3.

El propósito es emplear codificación por ángulos, mapeando cada característica resultante de aplicar las respectivas técnicas sobre su respectivo cúbit. Se ha acotado la dimensionalidad de salida a valores pares de características en el rango de 2 a 10 (2, 4, 6, 8 y 10). De este modo se reduce la carga computacional de la experimentación, manteniendo una muestra altamente representativa del efecto de la dimensionalidad sobre el circuito cuántico. Se ha establecido el límite superior en 10 cúbits debido a que el tiempo de simulación en hardware clásico escala de forma exponencial con cada cúbit adicional, manteniendo el tiempo de experimentación en un rango asumible.

PCA

Se seleccionó PCA por ser una técnica de reducción de dimensionalidad lineal ampliamente utilizada en el ámbito del aprendizaje automático. Se ha empleado la implementación proporcionada por la librería *scikit-learn* [11], utilizando la configuración de sus parámetros por defecto.

Se ajustaron cinco modelos PCA independientes, uno por cada dimensionalidad probada, empleando únicamente el conjunto de entrenamiento. Posteriormente, se aplicó la transformación correspondiente

proyectando tanto el conjunto de entrenamiento como de evaluación sobre el nuevo espacio latente.

UMAP

Se aplicó UMAP como una alternativa de reducción de dimensionalidad no lineal. UMAP es una técnica capaz de encontrar una proyección de baja dimensionalidad que preserva eficazmente la estructura topológica de los datos [8]. Se ha empleado la implementación oficial en Python desarrollada por los creadores de esta técnica, manteniendo los hiperparámetros establecidos por defecto.

Para su evaluación, se siguió el mismo procedimiento descrito para PCA. Se ajustó un modelo independiente sobre el conjunto de entrenamiento por cada dimensionalidad abordada, transformando posteriormente ambos conjuntos al nuevo espacio reducido.

Autoencoder

Por último, se ha propuesto el uso de una red neuronal profunda como tercer método de reducción de dimensionalidad. Dado que los conjuntos de datos seleccionados se encuentran formados por imágenes, se ha optado por una arquitectura basada en capas neuronales convolucionales.

La arquitectura implementada consta de un *encoder* y *decoder* simétricos. El *encoder* (Figura 3.1) dispone de dos capas convolucionales con funciones de activación ReLU para comprimir la resolución de la imagen desde los 28×28 píxeles hasta un mapa de características de 7×7 con 32 canales. El tensor resultante es aplanado y proyectado sobre el espacio latente de dimensión d mediante una capa completamente conexa.




Figura 3.1. Arquitectura del encoder propuesto.

El *decoder* (Figura 3.2) realiza el proceso inverso, donde primeramente el vector latente se mapea mediante una capa densa hacia un tensor 7×7 de 32 canales. Se aplican posteriormente dos capas convolucionales transpuestas para reconstruir la imagen original de dimensión 28×28 . Sobre la última capa se aplica una función de activación sigmoide para garantizar que los valores reconstruidos se encuentren en el rango $[0, 1]$.




Figura 3.2. Arquitectura del decoder propuesto.

Se realizó el entrenamiento de un autoencoder por cada conjunto de datos y dimensionalidad probada. El proceso de optimización del autoencoder se aplicó durante 25 épocas con una tasa de aprendizaje de 10^{-3} . Se empleó el algoritmo Adam como optimizador y el error cuadrático medio (MSE) como función de pérdida. El entrenamiento de los autoencoders se realizó sobre un subconjunto de instancias disjunto al empleado posteriormente en el entrenamiento y evaluación de los modelos de clasificación cuánticos.

3.1.2 VQC

El clasificador cuántico variacional (VQC) ha sido implementado mediante la librería de computación cuántica Qiskit [5], una herramienta que ha simplificado sustancialmente el diseño de los circuitos y la integración de los distintos componentes del circuito variacional. Para su incorporación en el flujo experimental, se ha desarrollado un *wrapper* personalizado que automatiza la construcción del VQC a partir de un fichero de configuración que especifica las características de sus componentes (*feature map*, *ansatz* y optimizador). También se ha implementado una función de *callback*, permitiendo monitorizar la evolución del entrenamiento, funcionalidad no disponible de forma nativa en la clase VQC de Qiskit Machine Learning.

3.1.2.1 Feature Map

A continuación se detallan los *feature map* empleados. La elección del circuito es dependiente del tipo de codificación aplicada.

Angle Encoding

Los *feature map* seleccionados han sido *ZZFeatureMap* y *ZFeatureMap* de la librería Qiskit Circuit. Para la implementación del *ZFeatureMap* (Figura 3.3) se ha empleado la clase *PauliFeatureMap* de Qiskit. Su configuración por defecto implementa un circuito equivalente al de un *ZZFeatureMap*. Por

este motivo, se modificó el parámetro *paulis* para aplicar puertas de rotación Pauli-Z . El método de codificación *Z* es de los más sencillos. En primer lugar se aplica una puerta Hadamard, creando un estado de superposición. Tras esto se aplica una rotación $R_z(2x_i)$, siendo x_i el valor de la característica i -ésima. Se trata de un circuito de profundidad reducida y en el que no se aplican puertas de dos cúbits, minimizando el riesgo de decoherencia.




Figura 3.3. Circuito cuántico *ZFeatureMap* de tres cúbits y dos repeticiones.

El *ZZFeatureMap* (Figura 3.4) extiende el circuito anterior mediante la introducción de entrelazamiento cuántico entre pares de cúbits. Para ello se aplica una puerta C-NOT, seguida de una rotación $R_z(2(\pi - x_i)(\pi - x_j))$ y una segunda C-NOT. Este circuito proyecta los datos sobre un espacio de Hilbert de mayor expresividad, permitiendo al modelo capturar relaciones no lineales complejas entre las variables del conjunto de datos.




Figura 3.4. Circuito cuántico *ZZFeatureMap* de tres cúbits, una repetición y entrelazamiento lineal, donde $\phi_{ij} = (\pi - x_i)(\pi - x_j)$.

Amplitude Encoding

Este tipo de codificación requiere mapear en cada amplitud el valor correspondiente a la variable del conjunto de datos. Qiskit ofrece esta implementación mediante la clase *RawFeatureVector* inicializada con el número de cúbits objetivo. Requiere que el vector de características dado como entrada cumpla la condición de normalización propia de la amplitud de un circuito cuántico. La implementación de la

inicialización del circuito que realiza Qiskit resulta incompatible con métodos de optimización basados en gradientes tal y como se indica en la documentación del método.

3.1.2.2 Ansatz

Respecto al *ansatz*, se fijó una configuración base uniforme para todos los experimentos asociados a la codificación por ángulos. Esta decisión viene influenciada por la necesidad de mitigar la explosión combinatoria y reducir el tiempo de cómputo derivado de la simulación de circuitos cuánticos en hardware clásico. Esta decisión estratégica centra el enfoque del estudio en el efecto que tiene la codificación cuántica de datos clásicos en el rendimiento. La configuración base empleada está formada por el circuito *RealAmplitudes* estructurado con dos repeticiones y una estrategia de entrelazamiento lineal (Figura 2.13).

Por el contrario, debido a la naturaleza del funcionamiento de la codificación por amplitudes, donde el *feature map* debe mapear cada característica sobre su correspondiente amplitud, no tienen cabida los hiperparámetros probados en la experimentación realizada con codificación por ángulos (dimensionalidad o configuración del *feature map*). Con el objetivo de enriquecer el estudio bajo este enfoque de codificación, se propuso un estudio de ablación. En él, se evalúa esta estrategia de codificación sobre el circuito base descrito, modificando un único componente del circuito a la vez: tipo de *ansatz* (aplicando *EfficientSU2*), el número de repeticiones (elevándolo a 3) y estrategia de entrelazamiento (aplicando entrelazamiento completo).

EfficientSU2 (Figura 3.5) se trata de un circuito parametrizado compuesto por la alternancia de capas de rotación y de entrelazamiento. $SU(2)$ hace referencia al grupo unitario especial de grado 2, formado por matrices unitarias con determinante 1, donde se incluyen las matrices de rotación Pauli. Concretamente este circuito intercala puertas Pauli Y y Z con puertas C-NOT creando el entrelazamiento en su configuración por defecto, que ha sido la empleada.




Figura 3.5. Estructura del Ansatz *EfficientSU2* de tres cúbits, una repetición y entrelazamiento lineal.

Bajo este enfoque de ablación, la incorporación de tres repeticiones y un entrelazamiento completo responde a la necesidad de evaluar el impacto de la dimensionalidad de parámetros entrenables y de

un mayor nivel de entrelazamiento. Esta estrategia permite determinar si aumentar la expresividad del circuito se ve reflejado en un aumento del rendimiento que compense la mayor exposición ante fenómenos de ruido.

3.1.2.3 Optimizador

El proceso de optimización se realizó mediante COBYLA [12], un optimizador libre de gradientes ampliamente utilizado en este área. Se contemplaron el uso de otras alternativas basadas en descenso de gradiente, sin embargo, la implementación de la estrategia de codificación por amplitud de la librería Qiskit, presenta incompatibilidades técnicas con los métodos basados en gradientes. Por este motivo, y para mantener un optimizador consistente a lo largo de todos los experimentos, COBYLA fue el seleccionado.

3.2 Conjuntos de datos empleados

Para evaluar el modelo híbrido propuesto, se ha diseñado una batería de pruebas de complejidad incremental empleando variantes binarizadas de conjuntos de datos clásicos en el área de visión por computador. Los conjuntos de datos de imágenes se caracterizan por su elevada dimensionalidad, dado que requieren de al menos un canal (escala de grises) o tres canales de color (RGB) para representar la información de cada píxel individual. Los conjuntos de datos seleccionados, MNIST [7] y FMNIST [17], se encuentran formados por imágenes de dígitos escritos a mano e imágenes de prendas de vestir respectivamente. En ambos conjuntos las imágenes se encuentran en escala de grises y con una resolución de 28x28 píxeles. Esto se traduce en un vector de 784 características que, dado el contexto de la era NISQ, resultan complejas de mapear sobre un ordenador cuántico debido a las limitaciones de cúbits y profundidad de los circuitos existentes.

A continuación se detallan los tres conjuntos de datos empleados.

MNIST 01

Subconjunto de MNIST formado por las clases '0' y '1'. Representa el problema de menor dificultad debido a la alta separabilidad espacial de sus características.

MNIST 36

Subconjunto de MNIST formado por las clases '3' y '6'. Pretende introducir un ligero nivel de dificultad con respecto al conjunto de datos anterior gracias a la mayor similitud morfológica que presentan los dígitos seleccionados.

FMNIST 06

Subconjunto de FMNIST formado por las clases '0' y '6', correspondientes a camiseta y camisa respectivamente. FMNIST se trata de un conjunto creado con el propósito de ser un reemplazo directo de su predecesor MNIST, conjunto demasiado sencillo para redes convolucionales y algoritmos de aprendizaje automático clásicos. FMNIST supone de por sí un problema de mayor dificultad que MNIST, y la selección de clases tan similares permitirá evaluar la capacidad de los modelos ante un verdadero reto.

3.3 Entorno de ejecución y tecnologías empleadas

La experimentación de este proyecto ha sido realizada en mi equipo local, utilizando una CPU AMD Ryzen 9 7845HX. El lenguaje de programación utilizado ha sido Python, y Qiskit el *framework* principal de desarrollo empleado en la construcción y simulación local de los clasificadores cuánticos empleados. También comentar el uso de bibliotecas clásicas de ciencia de datos empleadas en distintas etapas del proceso como el preprocesamiento, evaluación, y análisis de resultados. Aquí entrarían Scikit-learn, pandas, numpy, umap, matplotlib, seaborn, etc.

También destacar que PyTorch ha sido el *framework* utilizado para la implementación de los *autoencoders*, así como diversas pruebas realizadas durante las primeras fases del proyecto para construir prototipos de modelos híbridos.

Se ha utilizado Git para garantizar la integridad del código a lo largo de las distintas fases de la experimentación, facilitando el desarrollo experimental seguro.

3.4 Métricas de evaluación

Durante la experimentación se han recabado métricas estándar ampliamente utilizadas en la evaluación de clasificadores (*accuracy*, precisión, *recall*, *f1-score*, tiempo de ejecución y matriz de confusión). Adicionalmente se recogieron propiedades de los circuitos cuánticos críticas en el contexto NISQ, como la profundidad del circuito cuántico y el número total de parámetros entrenables.

El análisis de resultados y su discusión se ha centrado principalmente en dos ejes. Siendo el primero de ellos el rendimiento del modelo, evaluado mediante el *accuracy*; y el segundo, la viabilidad del modelo de ser ejecutado con éxito en un ordenador cuántico actual, teniendo en cuenta para ello la profundidad del circuito, el número de cúbits y el tipo de puertas lógicas empleadas.

4

Resultados experimentales

En este capítulo se presentan los resultados obtenidos con la experimentación realizada. Primeramente se analizan los modelos empleando codificación por ángulos (Sección 4.1), presentando primero los mejores resultados obtenidos, seguidos del análisis del efecto de los distintos hiperparámetros sobre el rendimiento y viabilidad final del modelo. La Sección 4.2 presenta los resultados de la experimentación realizada con la codificación por amplitud. En la Sección 4.3, se muestra una comparativa entre ambas estrategias de codificación. Finalmente, en la Sección 4.4, se discuten los resultados obtenidos teniendo en cuenta la viabilidad de los modelos variacionales bajo el contexto restrictivo de la era NISQ. Cabe mencionar que los resultados en bruto que sustentan este análisis han sido recopilados en el Anexo A de esta memoria.

4.1 Análisis de resultados de codificación por ángulos

En esta sección se presentan los resultados obtenidos mediante la codificación por ángulos.

4.1.1 Mejores soluciones

La Tabla 4.1 recopila las cinco configuraciones con mejor rendimiento para cada conjunto de datos. En ella se detalla la dimensionalidad del circuito y las características del *feature map* empleado (circuito, repeticiones y entrelazamiento), mostrando el *accuracy* y tiempo de entrenamiento.

Cabe destacar que, en el caso de emplear un *ZFeatureMap*, la columna de entrelazamiento se muestra vacía. Esto se debe a que la arquitectura del circuito se encuentra definida como un circuito de evolución de Pauli de primer orden. Por este motivo, las rotaciones son aplicadas estrictamente sobre un único cúbit y se omite el uso de puertas de múltiples cúbits para la generación de entrelazamiento.

Los resultados revelan como no existe una configuración dominante sobre los tres conjuntos de datos, indicando cierta dependencia de las características del conjunto de entrenamiento en el rendimiento de cada configuración. Se aprecia como para el conjunto de datos MNIST01, PCA junto con *FeatureMapZ* de dos repeticiones resulta claramente dominante sobre el resto. En MNIST36 también se aprecia la superioridad de UMAP, esta vez con el *FeatureMapZZ*. En FMNIST06 los mejores resultados también han sido obtenidos por UMAP con 10 cúbits.

Para el conjunto de datos MNIST, se ha alcanzado un *accuracy* del 98.5% y 93% en los subconjuntos de 01 y 36, respectivamente. Por su parte, FMNIST supone un reto mayor debido a su complejidad, lo cual se ha visto reflejado en el rendimiento de los modelos, donde el mejor resultado obtenido se sitúa en un 76%.

Tabla 4.1. Mejores configuraciones obtenidas para cada conjunto de datos, ordenadas por *accuracy* descendente y tiempo ascendente.

Conjunto de Datos	Reducción	Cúbits	Feature Map	Reps	Entrelazamiento	Accuracy (%)	Tiempo (MM:SS)
FMNIST06	UMAP	10	Z	1	—	76	18:02
FMNIST06	UMAP	10	Z	2	—	75	20:56
FMNIST06	UMAP	10	ZZ	1	Linear	72	21:09
FMNIST06	Autoencoder	2	Z	2	—	71	1:59
FMNIST06	Autoencoder	2	Z	1	—	69.5	2:12
MNIST01	PCA	10	Z	2	—	98.5	22:15
MNIST01	PCA	2	Z	2	—	98	2:33
MNIST01	PCA	4	Z	2	—	98	4:35
MNIST01	PCA	6	Z	2	—	98	6:54
MNIST01	PCA	8	Z	2	—	98	10:37
MNIST36	UMAP	8	ZZ	1	Linear	93	11:09
MNIST36	UMAP	8	ZZ	2	Linear	89.5	14:07
MNIST36	UMAP	8	ZZ	1	Circular	86	11:19
MNIST36	UMAP	10	Z	1	—	84.5	18:06
MNIST36	UMAP	10	ZZ	2	Linear	80	26:11

4.1.2 Análisis por parámetro

En esta sección se analiza el efecto que cada parámetro probado ha tenido sobre el rendimiento de los circuitos variacionales cuánticos.

Análisis por técnica de reducción y cúbits

A continuación, se analiza el efecto de cada técnica de reducción de dimensionalidad sobre el rendimiento del clasificador. Con el propósito de evaluar el comportamiento global y la robustez de cada método de reducción de forma independiente, las figuras muestran los resultados agregados a nivel de técnica de reducción. Este enfoque permite aislar la tendencia central de cada técnica frente a la variabilidad introducida por la configuración del circuito de codificación.

En el caso de MNIST01 (Figura 4.1), PCA muestra el mejor rendimiento, seguido de UMAP. Las tres técnicas de reducción muestran una elevada variabilidad indicando un alto impacto de la dimensionalidad o el *feature map* en el rendimiento final.




Figura 4.1. Boxplot del accuracy por técnica de reducción de dimensionalidad para MNIST01

Para el conjunto MNIST36 (Figura 4.2), las tres técnicas muestran un comportamiento similar en el rango intercuartílico, siendo el de UMAP ligeramente superior. UMAP sin embargo, presenta un bigote superior alargado y por lo tanto un techo de rendimiento notablemente mayor dado por un subconjunto de configuraciones del circuito subyacente, que se benefician particularmente de la capacidad de reducción de la técnica. En este contexto, la capacidad de UMAP para proyectar los datos

sobre un espacio latente preservando su estructura geométrica global, ha resultado de algún modo ventajosa.




Figura 4.2. Boxplot del accuracy por técnica de reducción de dimensionalidad para MNIST36

En FMNIST (Figura 4.3), se observa un comportamiento muy similar al observado sobre MNIST36. UMAP sigue siendo la técnica con mejor rendimiento máximo observado. Autoencoders en esta ocasión consigue obtener un rendimiento ligeramente superior a PCA, situándose como la segunda técnica con mayor techo de rendimiento.




Figura 4.3. Boxplot del accuracy por técnica de reducción de dimensionalidad para FMNIST06

Los diagramas anteriores muestran gran variabilidad derivada de la dimensionalidad y de las distintas configuraciones del *feature map* empleado, sobre el que se ha aplicado cada técnica de reducción. Para aislar estos efectos, las siguientes figuras muestran el rendimiento desglosado en función del número de cúbits. Esto permite comprobar si las técnicas son igualmente eficaces al proyectar sobre distintas dimensiones y observar el efecto exclusivo del *feature map* subyacente.

Al analizar el comportamiento por número de cúbits en MNIST01 (Figura 4.4), surgen patrones interesantes. La reducción mediante autoencoders parece mostrar en general una relación inversamente proporcional entre dimensionalidad y *accuracy*. PCA, en cambio, mantiene un rendimiento muy similar en casi todas las configuraciones mostrando una gran varianza. Por otro lado, UMAP presenta una tendencia general positiva en *accuracy* a mayor dimensionalidad, a excepción de la configuración con 2 cúbits que obtiene resultados medios. Destaca como el *ZFeatureMap* con dos repeticiones ha sido capaz de sacar partido a la reducción de PCA de forma independiente al número de dimensiones.




Figura 4.4. Boxplot del accuracy por técnica de reducción de dimensionalidad y número de cúbits para MNIST01

En la Figura 4.5 se observa como UMAP para 8 cúbits obtiene unos resultados casi dominantes sobre el resto de configuraciones. Tanto autoencoders como UMAP parecen seguir manteniendo sus ligeras correlaciones con la dimensionalidad. PCA mantiene un rendimiento estable ante las distintas dimensiones, salvo a excepción esta vez de 2 cúbits, donde que se muestra claramente superior al resto y con una varianza menor.




Figura 4.5. Boxplot del accuracy por técnica de reducción de dimensionalidad y número de cúbits para MNIST36

En el caso de FMNIST (Figura 4.6), el rendimiento general de las tres técnicas es similar entre sí. En UMAP destaca la configuración de 10 cúbits frente al resto, seguida de la reducción de dos dimensiones mediante autoencoders.




Figura 4.6. Boxplot del accuracy por técnica de reducción de dimensionalidad y número de cúbits para FMNIST06

Análisis por configuración del *feature map*

Para concluir el análisis de la codificación por ángulos, se presentan mapas de calor agregados a nivel de configuración del *feature map*. Se evalúa tanto el *accuracy* máximo como medio, lo que permite comprobar si los mejores resultados se adhieren a las tendencias globales, o si por el contrario son fenómenos puntuales independientes de la configuración del circuito.

En la Figura 4.7, se muestra el impacto del *feature map* sobre el conjunto de datos MNIST01, mostrando un comportamiento similar tanto para los valores máximos como para los medios. Destaca claramente la superioridad del circuito Z, siendo en torno a 10 puntos porcentuales superior al circuito ZZ. Emplear un mayor número de repeticiones también tiene cierto impacto positivo medio, aumentando el *accuracy* en el rango comprendido entre los 2.5 y 5.0 puntos porcentuales dependiendo de la configuración. El efecto del tipo de entrelazamiento en el caso del circuito ZZ, tiene un efecto marginal, siendo ligeramente mejor el lineal.




Figura 4.7. Heatmap mostrando el efecto del Feature Map empleado en MNIST01

Los resultados en MNIST36 (Figura 4.8) muestran un mejor desempeño medio del circuito Z, así como sucedía sobre MNIST01, habiéndose reducido la diferencia considerablemente. Este comportamiento sin embargo, no se translada sobre los mejores resultados obtenidos, donde la mejor solución media y máxima son configuraciones opuestas. En cuanto a las repeticiones aplicadas, se observa el efecto contrario al observado con anterioridad, donde configuraciones de 1 repetición tienen resultados por lo general mejores. También puede apreciarse un mejor rendimiento del entrelazamiento lineal,

siendo más notable cuando se aplica sobre dos repeticiones. Esto indica la fuerte importancia de la reducción de dimensionalidad aplicada y como el *feature map* se adapta a la misma.




Figura 4.8. Heatmap mostrando el efecto del Feature Map empleado en MNIST36

En el conjunto FMNIST (Figura 4.9), sí se mantiene la similitud entre los resultados máximos y medios. Se mantiene en la línea general donde el circuito Z obtiene los mejores resultados. También se mantiene lo observado en el conjunto de datos MNIST36, donde una repetición y entrelazamiento lineal obtienen mejores resultados que sus contrapartes.

Efecto de Feature Maps en FMNIST06




Figura 4.9. Heatmap mostrando el efecto del Feature Map empleado en FMNIST06

4.2 Análisis de resultados de codificación por amplitud

A continuación se muestran los resultados del experimento de ablación realizado sobre la codificación por amplitud. En él, se evalúa el rendimiento de la configuración base empleada (RealAmplitudes con 2 repeticiones y entrelazamiento lineal), modificando un único componente a la vez.

En la Figura 4.10, se muestra el efecto de los cambios aplicados sobre la configuración base del *ansatz*. El factor más determinante en la mejora de resultados ha sido el tipo de entrelazamiento. La configuración de entrelazamiento completo ha incrementado el accuracy en 10.5, 25 y 33.5 puntos para FMNIST, MNIST01 y MNIST36 respectivamente. El tipo de *ansatz* o aplicar tres repeticiones no han tenido un efecto tan pronunciado o estable, llegando incluso a empeorar el rendimiento del modelo base en el caso de MNIST36.

En la Tabla 4.2 se detalla el resultado de las doce configuraciones probadas con codificación por amplitud.

Se puede apreciar una clara diferencia en el tiempo de ejecución con respecto al enfoque mediante codificación por ángulos. El entrenamiento de modelos mediante esta técnica no ha bajado de las tres horas y media en el entorno local de computo. Mientras que con la codificación por ángulos no se superó la media hora de ejecución sobre las configuraciones más costosas computacionalmente.




Figura 4.10. Estudio ablación del efecto del Ansatz en codificación por amplitudes

Tabla 4.2. Resultados detallados del estudio de ablación sobre codificación por amplitud incluyendo métricas temporales y estructurales.

Dataset	Ansatz	Accuracy	Tiempo (H:M:S)	Ansatz Depth	Ansatz Params
MNIST01	Base	0.705	3:38:16	14	30
	SU2	0.66	3:31:22	17	60
	Entrelazamiento Completo	0.955	3:45:50	30	30
	3 Reps	0.745	3:42:38	17	40
MNIST36	Base	0.61	4:03:51	14	30
	SU2	0.54	3:38:43	17	60
	Entrelazamiento Completo	0.945	3:41:03	30	30
	3 Reps	0.52	3:42:10	17	40
FMNIST06	Base	0.625	3:46:01	14	30
	SU2	0.66	3:31:22	17	60
	Entrelazamiento Completo	0.73	3:47:16	30	30
	3 Reps	0.73	3:43:38	17	40

Gracias a las columnas donde se muestra la profundidad del *ansatz* probado y su número de parámetros, se aprecia como bajo este contexto, un mayor número de parámetros no ha sido el principal motivo de mejora, sino una mayor profundidad del circuito derivada de un entrelazamiento más denso y complejo entre cúbits dado por la configuración de entrelazamiento completo.

4.3 Comparación entre técnicas de codificación

Para finalizar esta sección se realizará una comparativa entre ambas estrategias de codificación incluyendo el tiempo como variable de análisis. Se incluyen únicamente los resultados de la codificación por amplitudes obtenidos empleando el *ansatz* base de forma que la comparación de las técnicas de codificación sea justa y bajo las mismas características.

Se emplea un diagrama de dispersión, representando sobre el eje horizontal el tiempo de entrenamiento y sobre el eje vertical el *accuracy*. Los resultados se encuentran agregados a nivel de estrategia de reducción aplicada y dimensionalidad. Se muestra el *accuracy* medio así como la desviación típica del tiempo de ejecución de cada nivel de agregación. El color de los puntos codifica la dimensionalidad empleada, mientras que la forma de los mismos indica el método de codificación empleado junto con la técnica de reducción si aplica.

En el dataset MNIST01 (Figura 4.11), se aprecia claramente la superioridad de PCA observada anteriormente. Teniendo resultados tan similares a lo largo de la dimensionalidad probada, escoger un circuito de menos cúbits ofrece ventajas en cuanto a menor tiempo de ejecución y menor número de puertas cuánticas disminuyendo el riesgo de decoherencia. Resulta evidente que la estrategia de codificación alternativa, codificación por amplitud, es inferior para este conjunto de datos dado el peor rendimiento y mayor tiempo de computación.

Ante el conjunto MNIST36 (Figura 4.12), se aprecia notoriamente la superioridad de la reducción de UMAP sobre 8 dimensiones. En este escenario, se podría llegar a tener en cuenta la solución de PCA con dos características, siendo la configuración alternativa en la frontera de pareto, con un tiempo de ejecución unas 10 veces menor. De nuevo el resultado obtenido con codificación por amplitud obtiene un peor rendimiento además del gran incremento en el tiempo de ejecución.




Figura 4.11. Comparativa de rendimiento y tiempo de ejecución de las estrategias de codificación.
MNIST01




Figura 4.12. Comparativa de rendimiento y tiempo de ejecución de las estrategias de codificación.
MNIST36

Finalmente, sobre FMNIST06 (Figura 4.13), se observa una situación muy similar al conjunto de datos MNIST36. Existe una clara dominancia en cuanto a *accuracy* de UMAP con 10 cúbits, y su alternativa en la frontera de pareto con una veinteava parte del tiempo de ejecución dada por autoencoders sobre dos cúbits. La alternativa mediante codificación por amplitud mantiene la tendencia observada anteriormente, sin ofrecer una mejora de rendimiento que compense el elevado tiempo de ejecución.




Figura 4.13. Comparativa de rendimiento y tiempo de ejecución de las estrategias de codificación.
FMNIST06

4.4 Discusión de resultados

Habiendo presentado los resultados en la sección anterior, se procede a realizar una valoración y análisis de los mismos.

En el aprendizaje automático clásico, el preprocesamiento de los datos supone una etapa crucial y con gran impacto en el rendimiento final obtenido. Particularmente, la reducción de dimensionalidad se aplica con el objetivo de reducir el ruido, tiempo de entrenamiento y sobreajuste de los modelos. En la experimentación realizada, se evidencia la estrecha relación entre el método de reducción aplicado y el

feature map empleado a la hora de obtener un buen rendimiento.

El *feature map* escogido tiene un gran impacto en el rendimiento final, observado en la gran variabilidad dada una misma configuración de reducción. Cómo se proyecta la información clásica en el espacio de estados cuánticos, puede llegar a convertir el problema de clasificación en una tarea trivial, con clases fácilmente separables por el circuito cuántico parametrizable.

Sin embargo, tal y como estipula el teorema *No Free Lunch*, no se ha observado una técnica de reducción o configuración de *feature map* dominante a lo largo de los tres conjuntos de datos empleados.

En cuanto a las técnicas de reducción, UMAP ha mostrado un gran rendimiento en los tres conjuntos de datos, obteniendo sus mejores resultados con un número mayor de cúbits empleados de forma general. PCA ha sido capaz de superar a UMAP sobre el conjunto de datos MNIST01, mostrando un gran rendimiento con tan solo dos cúbits. Esto supone un menor tiempo de entrenamiento y un circuito cuántico menos profundo y con un menor número de puertas lógicas. Características ideales en el contexto actual de hardware cuántico NISQ, donde las puertas lógicas tienen tasas de error altas y se produce la decoherencia de los cúbits. La reducción mediante autoencoders, aunque sin haber mostrado el mejor rendimiento en ningún conjunto de datos, ha conseguido hacerse un hueco como alternativa en la frontera de pareto empleando únicamente 2 cúbits en FMNIST. Esta técnica ha demostrado un mejor rendimiento a menor dimensionalidad.

En relación a los *feature maps* empleados, el circuito Z ha demostrado un gran rendimiento, obteniendo la mejor configuración sobre MNIST01 y FMNIST, siendo un circuito más simple que ZZ al no aplicar entrelazamiento entre cúbits. Esta es una ventaja notable en el contexto de la era NISQ, al no emplear puertas de dos cúbits con una tasa de error mayor. Por otro lado, tampoco se ha observado una ventaja universal al uso de circuitos con mayor número de repeticiones, siendo dependiente del conjunto de datos, y del resto de parámetros del *feature map* en algunos casos. Debido a las limitaciones del hardware cuántico actual, son preferibles circuitos con menor profundidad, por lo que evaluar el impacto a nivel de *accuracy* y tiempo de ejecución de este parámetro es esencial.

En lo que respecta a la estrategia de entrelazamiento, es vital tener en cuenta el impacto que tiene en el número de puertas C-NOT. Estas puertas de dos cúbits tienen una mayor tasa de error asociada. Las estrategias probadas mediante codificación por ángulos no presentan una gran diferencia en cuanto al número de puertas C-NOT que introducen. Además se observa cómo el entrelazamiento lineal ha sido consistentemente mejor empleando una puerta C-NOT menos por repetición del circuito. La estrategia de entrelazamiento completo empleada en codificación por amplitud sí que incrementa

considerablemente el número de puertas al entrelazar todos los cúbits entre sí. Esta estrategia ha permitido obtener resultados bastante mejores que el modelo base a costa de emplear un *ansatz* más complejo.

Por otro lado, la estrategia de codificación por amplitud posee la ventaja de ser capaz de codificar 2^n características en tan solo n cúbits. Esta capacidad viene a costa de *feature maps* muy profundos capaces de ajustar cada amplitud al valor correspondiente del vector de entrada. La complejidad de estos circuitos, además de aumentar enormemente el tiempo de ejecución necesario, los hace en gran medida incompatibles con las restricciones actuales. En este proyecto se ha visto que existen métodos de abordar conjuntos de datos de gran dimensionalidad mediante otras estrategias de codificación sin recurrir a mapear sobre las amplitudes, obteniendo resultados incluso mejores y empleando circuitos cuánticos compatibles con el hardware actual.

5

Conclusiones y trabajo futuro

En este capítulo se presentan las conclusiones alcanzadas tras la realización de este proyecto, así como posibles líneas de trabajo futuro con las que expandir el alcance del mismo. Finalmente se incluye una pequeña valoración personal de lo que ha supuesto la realización de este trabajo.

5.1 Conclusiones

En este Trabajo de Fin de Master se ha estudiado la viabilidad de la aplicación de técnicas de reducción de dimensionalidad como puente entre el potencial teórico del aprendizaje automático cuántico y su aplicabilidad ante problemas de gran dimensionalidad. En el contexto de la computación cuántica en la era NISQ, donde los circuitos se encuentran limitados en cuanto a profundidad y número de cúbits, la codificación de la información clásica es un factor limitante en cuanto a la aplicación de modelos QML y las comparativas de *benchmarking* a las que pueden someterse de forma experimental. Bajo este escenario de restricciones de hardware debido al efecto de la decoherencia, se han cumplido con éxito los objetivos planteados al inicio de este proyecto.

El estudio detallado del estado del arte permitió delimitar una experimentación fundamentada y orientada a configuraciones con interés práctico dentro de las limitaciones tecnológicas actuales. Se diseñó e implementó con éxito un enfoque híbrido clásico-cuántico integrando una capa previa de reducción de dimensionalidad clásica sobre un modelo de aprendizaje cuántico variacional.

Asimismo, el modelo híbrido implementado se integró en un marco de experimentación modular y

parametrizable mediante ficheros de configuración. Esta infraestructura permitió la automatización de la ejecución por lotes de entrenamiento, generando *logs* con los resultados experimentales empleados posteriormente en el análisis y evaluación de los modelos.

La evaluación realizada demuestra el impacto positivo que tiene la reducción de dimensionalidad sobre la implementación de modelos híbridos clásico-cuánticos, habilitando su aplicación sobre conjuntos de datos que, de otro modo, resultarían impracticables. Este enfoque permite la representación de forma efectiva, minimizando la pérdida de información, sobre circuitos cuánticos de menor escala aptos para la era NISQ, sin necesitar recurrir a técnicas de alto coste computacional como la codificación por amplitud. No obstante, los resultados experimentales revelan que no existe una configuración óptima de forma universal, mostrando una clara dependencia entre las características del conjunto de datos y la configuración del modelo. En este sentido, PCA y *Autoencoders* han mostrado en general un buen rendimiento con menor dimensión, mientras que UMAP ha sido capaz de superar dicho rendimiento sobre dos de los tres conjuntos de datos a cambio de emplear un mayor número de cúbits.

A nivel de circuito cuántico, el rendimiento del *feature map* resultó ser también muy dependiente del conjunto de datos. El *ZFeatureMap* a pesar de ser un circuito más sencillo que no aplica entrelazamiento, demostró mejores resultados sobre dos de los conjuntos de datos probados por encima de *ZZFeatureMap*, lo cual supone una ventaja en su ejecución sobre ordenadores NISQ debido a su menor tasa de error. Asimismo, la comparativa con la estrategia de codificación por amplitud, evidenció las ventajas de aplicar la arquitectura híbrida propuesta. Si bien permite almacenar 2^n características empleando n cúbits, se ha demostrado la necesidad de incluir un entrelazamiento completo en el *ansatz* para obtener resultados comparables a los obtenidos mediante codificación por ángulos. El sobre coste asociado a la estrategia de codificación no viene acompañado de un rendimiento que lo justifique, al menos sobre el marco de experimentación probado.

5.2 Trabajo futuro

Partiendo de las conclusiones obtenidas y las limitaciones tecnológicas presentes durante el desarrollo del proyecto, se proponen a continuación posibles vías con las que expandir la investigación realizada:

- **Mejorar la significancia estadística.** Replicar el conjunto de experimentos realizados aplicando una estrategia de validación cruzada. Esto permitirá obtener resultados estadísticamente significativos dando mayor fiabilidad a las conclusiones obtenidas.

- **Experimentación sobre hardware cuántico.** La totalidad de las experimentaciones han sido realizadas por medio de simulación clásica de los sistemas cuánticos. Realizar la experimentación sobre hardware cuántico real permitirá estudiar con mayor fidelidad la viabilidad real de los circuitos propuestos en un entorno de ruido real.
- **Extensión de la investigación sobre el *ansatz*.** Este proyecto se ha centrado principalmente en estudiar el efecto de la estrategia de codificación. También es de interés profundizar en el estudio del elemento encargado de aprender la separación entre clases, entendiendo mejor como se comporta en relación a las etapas previas de preprocesamiento.
- **Estudiar la escalabilidad de los modelos.** El estudio realizado se encuentra acotado en un rango bajo de cúbits debido a las limitaciones del tiempo de simulación. Sería de interés aumentar progresivamente la dimensionalidad del circuito estudiando el comportamiento de las técnicas empleadas y la posible aparición de *barren plateaus*. Sobre circuitos reales, se deben contemplar además las restricciones de conectividad física de cúbits, lo que requiere el uso de puertas SWAP para acercar cúbits que interaccionan entre sí. Esto provoca un aumento de la profundidad y la tasa de error, limitando el número de cúbits útiles.
- **Hibridación sobre codificación por amplitud.** No se han explorado los beneficios propios de las técnicas de reducción de características sobre la codificación por amplitud. Reduciendo las características a mapear, se puede llegar a suavizar el mayor inconveniente de este método, la profundidad de su *feature map*.

5.3 Valoración personal

Este Trabajo de Fin de Máster ha resultado ser una experiencia muy positiva. A pesar de las diversas limitaciones temporales durante el proceso de realización de este proyecto y habiéndome quedado con el deseo de ampliar el alcance del mismo, ha sido una oportunidad de introducirme en un área en auge y con gran relevancia en la actualidad. Sintiendo que tan solo he rascado la superficie de la computación cuántica, este proyecto me ha abierto la puerta a seguir aprendiendo y reavivado mi interés por la física y matemáticas. En definitiva ha supuesto un reto intelectual, al abordar un área de conocimiento desconocida en un inicio, que me ha permitido poner en práctica las habilidades y conocimientos adquiridos durante mi trayectoria académica además de expandirlos.



Resultados Completos

Este capítulo anexo recoge de forma detallada los resultados experimentales que fundamentan el análisis y la discusión desarrollados en el Capítulo 4 de esta memoria. En total se presentan cuatro tablas: las tres primeras corresponden a un análisis de posición relativa (*ranking*), diseñado para evaluar el rendimiento global de un parámetro específico frente al resto de las configuraciones. La última tabla muestra los valores de exactitud (*accuracy*) absolutos obtenidos en la totalidad de las simulaciones.

La estructura de estas tablas es jerárquica y cuenta con múltiples niveles de indexación tanto en filas como en columnas. En las columnas, el primer nivel especifica el conjunto de datos evaluado, mientras que el segundo nivel define la variable objetivo del análisis. Por su parte, las filas organizan de manera sistemática las combinaciones de los parámetros del modelo a través de tres niveles jerárquicos.

Los valores numéricos de las matrices de posición relativa indican el orden de rendimiento del parámetro estudiado bajo una combinación fija del resto de variables. De este modo, un valor de 1 representa la configuración óptima para ese escenario concreto. La última fila de estas tablas calcula el valor medio de dicha posición. Por tanto, un promedio inferior refleja un comportamiento general más robusto y eficiente a lo largo de todo el marco experimental.

A continuación, en la Tabla [A.1](#), se analiza el impacto de la técnica de reducción de dimensionalidad empleada, manteniendo fijos el número de cúbits y la arquitectura del *feature map*.

Dataset			FMNIST06			MNIST01			MNIST36		
Reducción			Autoencoder	PCA	UMAP	Autoencoder	PCA	UMAP	Autoencoder	PCA	UMAP
Cúbits	Feature Map	FM Reps									
2	z	1	1	3	2	2	1	3	2	1	3
		2	1	3	2	2	1	3	1	1	3
	zz-circular	1	1	2	3	3	2	1	2	1	3
		2	1	2	2	1	2	3	2	1	3
	zz-linear	1	1	2	3	3	2	1	2	1	3
		2	2	1	3	1	2	3	2	1	3
4	z	1	2	1	3	3	1	2	2	1	3
		2	3	1	2	3	1	2	2	3	1
	zz-circular	1	3	1	1	2	1	3	2	3	1
		2	1	3	2	2	1	3	2	3	1
	zz-linear	1	1	1	3	3	1	2	2	1	3
		2	2	1	3	2	1	3	2	1	3
6	z	1	1	2	3	3	1	2	3	1	2
		2	1	2	3	2	1	3	3	2	1
	zz-circular	1	1	2	2	3	2	1	3	1	2
		2	2	3	1	2	1	3	2	3	1
	zz-linear	1	3	2	1	3	1	1	1	2	3
		2	1	3	1	2	1	3	1	2	3
8	z	1	3	1	2	3	1	2	3	2	1
		2	3	1	2	3	1	2	3	2	1
	zz-circular	1	1	2	3	3	1	2	3	2	1
		2	1	3	1	3	1	2	2	3	1
	zz-linear	1	2	3	1	3	1	2	3	2	1
		2	2	1	3	3	1	2	3	2	1
10	z	1	2	2	1	3	1	2	3	2	1
		2	2	3	1	3	1	2	1	2	3
	zz-circular	1	2	3	1	3	2	1	2	3	1
		2	2	3	1	3	1	2	3	2	1
	zz-linear	1	2	3	1	3	2	1	3	2	1
		2	3	2	1	3	2	1	3	2	1
Media			1.77	2.07	1.93	2.60	1.27	2.10	2.27	1.83	1.87

Tabla A.1. Rendimiento relativo según la técnica de reducción de dimensionalidad.

A continuación, en la Tabla A.2, se analiza el impacto de la arquitectura del *feature map*, manteniendo

fijas las repeticiones y dimensionalidad del mismo, así como la técnica de reducción empleada.

		Dataset	FMNIST06			MNIST01			MNIST36		
		Feature Map	z	zz-circular	zz-linear	z	zz-circular	zz-linear	z	zz-circular	zz-linear
Cúbits	Reducción	FM Reps									
2	Autoencoder	1	1	3	2	1	3	2	3	1	2
		2	1	2	2	1	1	1	3	1	1
	PCA	1	3	1	1	1	2	2	3	1	1
		2	2	3	1	1	2	2	3	1	1
	UMAP	1	1	2	2	3	1	1	3	1	1
		2	1	2	2	3	1	1	1	1	2
4	Autoencoder	1	3	2	1	1	2	3	1	3	2
		2	2	3	1	1	2	2	1	3	2
	PCA	1	1	2	2	1	2	3	1	3	2
		2	2	3	1	1	3	2	1	3	2
	UMAP	1	3	1	2	1	3	2	1	3	2
		2	1	2	3	1	3	2	1	2	3
6	Autoencoder	1	1	3	2	1	3	2	3	2	1
		2	2	3	1	1	3	2	3	2	1
	PCA	1	1	3	1	1	3	2	1	2	3
		2	1	2	3	1	3	2	1	3	2
	UMAP	1	2	3	1	1	2	3	1	2	3
		2	2	3	1	1	2	3	1	2	3
8	Autoencoder	1	2	1	2	1	3	2	3	1	2
		2	3	1	2	1	3	2	2	1	2
	PCA	1	1	2	3	1	3	2	1	2	3
		2	2	3	1	1	3	2	1	3	2
	UMAP	1	1	3	2	1	2	3	3	2	1
		2	2	1	3	1	2	2	2	3	1
10	Autoencoder	1	1	2	3	1	3	2	2	1	3
		2	1	3	2	1	2	3	1	3	2
	PCA	1	1	2	3	1	3	2	1	3	2
		2	2	3	1	1	3	2	1	3	2
	UMAP	1	1	3	2	3	2	1	1	3	2
		2	1	3	2	2	3	1	2	3	1
Media			1.60	2.33	1.83	1.23	2.43	2.03	1.73	2.17	1.90

Tabla A.2. Rendimiento relativo según el feature map.

A continuación, en la Tabla A.3, se analiza el impacto de la dimensionalidad del circuito cuántico, la técnica de reducción y la arquitectura del *feature map*.

		Dataset	FMNIST06					MNIST01					MNIST36				
		Qubits	2	4	6	8	10	2	4	6	8	10	2	4	6	8	10
FM Reprs	Reducción	Feature Map															
1	Autoencoder	z	1	4	2	5	3	1	5	2	2	4	2	1	4	5	3
		zz-circular	1	4	5	3	2	1	4	2	5	3	1	3	5	4	2
		zz-linear	1	2	3	5	4	2	5	1	4	3	1	3	2	4	5
	PCA	z	5	1	2	2	2	1	1	1	1	1	3	1	3	2	5
		zz-circular	1	2	5	3	4	2	1	3	4	5	1	5	2	2	4
		zz-linear	1	2	2	4	5	1	5	2	3	3	1	4	5	3	2
	UMAP	z	2	5	4	3	1	5	4	2	1	3	5	4	3	2	1
		zz-circular	3	2	4	5	1	1	5	2	4	3	3	4	5	1	2
		zz-linear	3	5	2	4	1	2	5	3	4	1	3	4	5	1	2
2	Autoencoder	z	1	4	3	5	2	2	4	1	2	5	3	2	5	4	1
		zz-circular	1	3	5	2	4	1	2	3	5	4	1	4	3	2	5
		zz-linear	3	2	1	5	4	1	3	2	4	5	1	3	2	5	4
	PCA	z	5	3	1	2	4	2	2	2	2	1	2	3	3	3	1
		zz-circular	1	5	4	3	1	3	2	5	3	1	1	4	2	5	3
		zz-linear	3	4	5	1	2	5	3	1	4	1	1	3	4	4	2
	UMAP	z	2	3	4	5	1	5	3	4	1	2	5	2	3	1	3
		zz-circular	5	3	4	2	1	3	5	4	2	1	5	2	4	1	3
		zz-linear	3	5	2	4	1	3	4	4	2	1	5	4	3	1	2
Media			2.33	3.28	3.22	3.50	2.39	2.28	3.50	2.44	2.94	2.61	2.44	3.11	3.50	2.78	2.78

Tabla A.3. Rendimiento relativo según la dimensionalidad del circuito.

Por último, se presenta la totalidad de los resultados en bruto obtenidos durante la fase de experimentación (véase la Tabla A.4). Esta matriz se encuentra estructurada con el fin de facilitar la lectura en torno al efecto de las técnicas de reducción de dimensionalidad clásicas. En este escenario, al mostrar los valores de *accuracy* normalizados en el rango $[0, 1]$, un valor numérico mayor denota un rendimiento superior del modelo.

Dataset			FMNIST06			MNIST01			MNIST36		
	Reducción	Autoencoder	PCA	UMAP	Autoencoder	PCA	UMAP	Autoencoder	PCA	UMAP	
Qubits	Feature Map	FM Reps									
2	z	1	0.70	0.61	0.62	0.72	0.92	0.62	0.70	0.70	0.62
		2	0.71	0.58	0.62	0.80	0.98	0.62	0.69	0.69	0.60
	zz-circular	1	0.66	0.66	0.62	0.66	0.74	0.82	0.74	0.76	0.66
		2	0.60	0.54	0.54	0.80	0.78	0.72	0.71	0.74	0.56
	zz-linear	1	0.68	0.66	0.62	0.68	0.74	0.82	0.72	0.76	0.66
		2	0.60	0.64	0.54	0.80	0.78	0.72	0.71	0.74	0.56
4	z	1	0.57	0.64	0.52	0.62	0.92	0.72	0.70	0.72	0.64
		2	0.58	0.60	0.58	0.74	0.98	0.76	0.73	0.68	0.74
	zz-circular	1	0.60	0.63	0.63	0.61	0.76	0.58	0.62	0.59	0.62
		2	0.57	0.49	0.55	0.69	0.78	0.64	0.56	0.54	0.70
	zz-linear	1	0.63	0.63	0.59	0.58	0.72	0.66	0.64	0.64	0.63
		2	0.60	0.62	0.48	0.69	0.80	0.65	0.60	0.63	0.59
6	z	1	0.65	0.63	0.60	0.72	0.92	0.84	0.56	0.70	0.66
		2	0.62	0.62	0.55	0.82	0.98	0.75	0.56	0.68	0.69
	zz-circular	1	0.58	0.52	0.52	0.66	0.73	0.78	0.60	0.66	0.62
		2	0.53	0.50	0.55	0.68	0.72	0.66	0.58	0.57	0.64
	zz-linear	1	0.61	0.63	0.64	0.70	0.74	0.74	0.66	0.64	0.62
		2	0.64	0.46	0.64	0.74	0.80	0.65	0.66	0.62	0.61
8	z	1	0.56	0.63	0.62	0.72	0.92	0.88	0.52	0.72	0.78
		2	0.52	0.61	0.55	0.80	0.98	0.91	0.58	0.68	0.77
	zz-circular	1	0.62	0.58	0.50	0.56	0.72	0.70	0.61	0.66	0.86
		2	0.59	0.53	0.59	0.55	0.78	0.77	0.60	0.51	0.74
	zz-linear	1	0.56	0.55	0.60	0.63	0.73	0.70	0.57	0.64	0.93
		2	0.56	0.68	0.50	0.64	0.79	0.77	0.58	0.62	0.90
10	z	1	0.63	0.63	0.76	0.66	0.92	0.74	0.64	0.70	0.84
		2	0.64	0.59	0.75	0.66	0.98	0.86	0.76	0.72	0.69
	zz-circular	1	0.62	0.57	0.70	0.62	0.70	0.78	0.66	0.62	0.67
		2	0.55	0.54	0.60	0.66	0.78	0.78	0.55	0.56	0.64
	zz-linear	1	0.58	0.55	0.72	0.64	0.73	0.84	0.50	0.65	0.73
		2	0.58	0.67	0.68	0.62	0.80	0.88	0.59	0.66	0.80
Media			0.60	0.59	0.60	0.68	0.82	0.74	0.63	0.66	0.69

Tabla A.4. Rendimiento bruto según la técnica de reducción de dimensionalidad.

Bibliografía

- [1] Andrew Arrasmith et al. "Effect of barren plateaus on gradient-free optimization". In: *Quantum* 5 (Oct. 2021), p. 558. ISSN: 2521-327X. DOI: [10.22331/q-2021-10-05-558](https://doi.org/10.22331/q-2021-10-05-558). URL: <https://doi.org/10.22331/q-2021-10-05-558>.
- [2] Hillol Biswas. *Data Encoding for VQC in Qiskit, A Comparison With Novel Hybrid Encoding*. 2025. arXiv: 2503.14062 [quant-ph]. URL: <https://arxiv.org/abs/2503.14062>.
- [3] Benyamin Ghogh et al. *Elements of Dimensionality Reduction and Manifold Learning*. Jan. 2023. ISBN: 978-3-031-10601-9. DOI: [10.1007/978-3-031-10602-6](https://doi.org/10.1007/978-3-031-10602-6).
- [4] IBM Quantum. *IBM Quantum Roadmap*. International Business Machines (IBM). 2025. URL: <https://www.ibm.com/downloads/documents/us-en/1443d5cda24021e4> (visited on 06/04/2026).
- [5] Ali Javadi-Abhari et al. *Quantum computing with Qiskit*. 2024. arXiv: 2405.08810 [quant-ph]. URL: <https://arxiv.org/abs/2405.08810>.
- [6] I.T. Jolliffe. *Principal component analysis (2nd edition)*. Berlin: Springer Verlag, 2002.
- [7] Yann LeCun et al. "Gradient-Based Learning Applied to Document Recognition". In: *Proceedings of the IEEE*. Vol. 86. 11. 1998, pp. 2278–2324. URL: <http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.42.7665>.
- [8] Leland McInnes, John Healy, and James Melville. "Umap: Uniform manifold approximation and projection for dimension reduction". In: *arXiv preprint arXiv:1802.03426* (2018).
- [9] Michael A. Nielsen and Isaac L. Chuang. *Quantum Computation and Quantum Information: 10th Anniversary Edition*. Cambridge University Press, 2010.
- [10] Karl Pearson. "LIII. On lines and planes of closest fit to systems of points in space". In: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 2.11 (1901), pp. 559–572. DOI: [10.1080/14786440109462720](https://doi.org/10.1080/14786440109462720). eprint: <https://doi.org/10.1080/14786440109462720>. URL: <https://doi.org/10.1080/14786440109462720>.
- [11] F. Pedregosa et al. "Scikit-learn: Machine Learning in Python". In: *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.

- [12] M. J. D. Powell. "A Direct Search Optimization Method That Models the Objective and Constraint Functions by Linear Interpolation". In: *Advances in Optimization and Numerical Analysis*. Ed. by Susana Gomez and Jean-Pierre Hennart. Dordrecht: Springer Netherlands, 1994, pp. 51–67. ISBN: 978-94-015-8330-5. DOI: [10 . 1007 / 978 - 94 - 015 - 8330 - 5 _ 4](https://doi.org/10.1007/978-94-015-8330-5_4). URL: [https : // doi . org / 10 . 1007 / 978 - 94 - 015 - 8330 - 5 _ 4](https://doi.org/10.1007/978-94-015-8330-5_4).
- [13] John Preskill. "Quantum Computing in the NISQ era and beyond". In: *Quantum* 2 (Aug. 2018), p. 79. ISSN: 2521-327X. DOI: [10 . 22331 / q - 2018 - 08 - 06 - 79](https://doi.org/10.22331/q-2018-08-06-79). URL: [https : // doi . org / 10 . 22331 / q - 2018 - 08 - 06 - 79](https://doi.org/10.22331/q-2018-08-06-79).
- [14] M. Schuld and F. Petruccione. *Machine Learning with Quantum Computers*. Quantum Science and Technology. Springer International Publishing, 2021. ISBN: 9783030830977. URL: [https : // books . google . es / books ? id = 1ziHzgEACAAJ](https://books.google.es/books?id=1ziHzgEACAAJ).
- [15] Michał Stęchły. *Introduction to Variational Quantum Algorithms*. 2024. arXiv: [2402 . 15879](https://arxiv.org/abs/2402.15879) [quant-ph]. URL: [https : // arxiv . org / abs / 2402 . 15879](https://arxiv.org/abs/2402.15879).
- [16] Yunfei Wang and Junyu Liu. "A comprehensive review of quantum machine learning: from NISQ to fault tolerance". In: *Reports on Progress in Physics* 87.11 (Oct. 2024), p. 116402. ISSN: 1361-6633. DOI: [10 . 1088 / 1361 - 6633 / ad7f69](http://dx.doi.org/10.1088/1361-6633/ad7f69). URL: [http : // dx . doi . org / 10 . 1088 / 1361 - 6633 / ad7f69](http://dx.doi.org/10.1088/1361-6633/ad7f69).
- [17] Han Xiao, Kashif Rasul, and Roland Vollgraf. "Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms". In: *CoRR* abs/1708.07747 (2017). arXiv: [1708 . 07747](http://arxiv.org/abs/1708.07747). URL: [http : // arxiv . org / abs / 1708 . 07747](http://arxiv.org/abs/1708.07747).



UNIVERSIDAD
DE MÁLAGA

| **uma.es**

ETS. de Ingeniería Informática

Bulevar Louis Pasteur, 35

Campus de Teatinos

29071 Málaga